Comparative Benchmarking of Neural OCR Methods for Handwritten Word Recognition in Medical Prescription Images under Limited-Data and Computational Constraints

Samuel F. Santos*
Universidade Estadual de Santa Cruz

Resumo

This study presents a practical comparison of CNN-based and Transformer-based models for handwritten word recognition in medical prescription images. Two source datasets, RxHandBD and Doctor's Handwritten PrescriptionBD, were evaluated individually and in a combined training scenario. From-scratch training was used for a CNN baseline formulated as a closed-set word classifier and for a CNN-BiLSTM sequence-recognition model, whereas the pre-trained TrOCR and PARSeq Transformers were fine-tuned for character-sequence transcription. The study examines how dataset characteristics, training regimes, and task formulations affect recognition performance, model limitations, and training cost under limited-data conditions.

Keywords: Neural Network; Convulation; Transformers; Artificial Intelligence.

1 Introduction

During medical appointments, patients are often issued a medical prescription containing information about medications and treatment instructions intended to support their recovery. However, the readability of these prescriptions is frequently affected by the physician's handwriting and the context in which they are written. Factors such as the urgency of medical care and the high demand for patient consultations can negatively impact the legibility of handwritten prescriptions, making their interpretation more challenging for both healthcare professionals and patients.

As a consequence, medical prescriptions often present low legibility, making their interpretation challenging for both pharmacists and patients. This difficulty has led several countries to adopt digital prescription systems as a way to reduce interpretation errors and improve patient safety. However, this transition has not occurred universally, and handwritten prescriptions are still widely used in many healthcare settings.

Therefore, it is important to investigate and understand the challenges of applying Optical Character Recognition (OCR) to handwritten medical prescriptions, including both textual characters and medical symbols. Furthermore, it is relevant to evaluate whether the knowledge and techniques developed for this domain can be generalized to other types of handwritten documents.

It is understood that handwritten manuscripts exhibit several characteristics relevant to this study, as they are composed of simplified geometric shapes and structural patterns that can be interpreted from the symbols present in the writing. Figures 1a and 1b illustrate these fundamental shapes while also highlighting the presence of noise and irregularities resulting from environmental conditions and the writing process, as previously discussed. Consequently, these

*E-mail: lacerdasamuel26@gmail.com

images provide an appropriate basis for investigating complex geometric patterns, offering a representative depiction of the structural characteristics inherent to handwriting.



(a) (b)

Figura 1: Geometric Characteristics of Handwritten Medical Prescriptions

In the context of neural networks, it is important to evaluate the ability of different architectures to learn and recognize handwriting structures. This motivation is justified by the possibility of automatically classifying medical prescriptions and by the potential to use these structures as a basis for learning robust representations applicable to problems involving more complex geometric patterns, as demonstrated in [1].

The characteristics present in handwritten medical prescriptions are particularly relevant for model training because they reflect the natural variability introduced during the handwriting process. Furthermore, handwritten prescriptions incorporate variations arising from the writing process, the writer's individual style, and external influences. This differs from synthetic data, which generally exhibit more controlled patterns and lower variability.

Consequently, these characteristics play an important role in neural network training by enabling models to learn more robust representations with greater generalization capability when dealing with the variability found in real-world scenarios.

However, neural network training using handwritten medical prescription data faces challenges related to data scarcity, image quality, and annotation quality. Data scarcity results from the limited availability of publicly available datasets for training, making it necessary to adopt data augmentation techniques to increase the number and diversity of training samples. Regarding image quality, this challenge is associated with the age of existing datasets, as older datasets often contain images with lower resolution, reduced sharpness, and a higher incidence of artifacts. These factors should be carefully considered during the data collection and preprocessing stages. Annotation quality also represents an important challenge, as each dataset may exhibit limitations associated with regional characteristics. Consequently, there is no guarantee that a dataset collected in the United States, for example, shares the same handwriting patterns, terminology, and structural characteristics as medical prescriptions written in Brazil or European countries. These differences reflect linguistic, cultural, and healthcare system variations across regions. To address these challenges, different strategies were adopted throughout this study to mitigate their impact and improve both the quality of model training and the generalization capability of the proposed neural networks.

Despite the limitations related to data availability, this study does not aim to collect new handwritten medical prescriptions or construct a novel dataset. Nevertheless, an adequate number of training samples is required to effectively train the neural network models. To address this limitation, data augmentation techniques are employed to increase data diversity

and improve the generalization capability of the models.

In this project, two datasets will be used to train the neural networks. Initially, each dataset will be used independently, allowing the performance of the models to be evaluated on each dataset separately. Subsequently, a new training process will be conducted using a combination of both datasets. This strategy aims to increase the number of available training samples while reducing the likelihood of overfitting.

The datasets selected for this study were RxHandBD [2] and PrescriptionBD [3], as they present characteristics that are well suited to the proposed task. Then, after applying data augmentation techniques and organizing the training sets, the data will be ready to be used for training the neural networks.

To conduct these experiments, four neural network architectures were evaluated: two based on Convolutional Neural Networks (CNNs) and two based on Transformers. The convolutional architectures selected were a CNN Baseline and a CNN-BiLSTM. They were chosen because they require lower computational cost and are less dependent on large volumes of training data, characteristics that are consistent with the data scarcity scenario addressed in this study.

The Transformer-based architectures selected were TrOCR and PARSeq. Both models were initialized from pre-trained weights and subsequently fine-tuned for the proposed task. This approach leverages knowledge acquired during pre-training, reducing the need for large task-specific datasets.

The performance evaluation was conducted by considering the characteristics of each architecture. Accordingly, the CNN-based models were analyzed within the training from scratch paradigm, whereas the Transformer-based models were evaluated under the fine-tuning paradigm. Thus, the comparisons were performed within the context of each training strategy, avoiding direct comparisons that could lead to misleading interpretations due to the inherent differences between their training processes.

A dedicated hardware platform was used throughout this study to support the continuous training and evaluation of the proposed models. The hardware specifications are presented in Table 1.

Tabela 1: Hardware configuration used in the experiments.

Component	**Specification**
CPU	Intel Xeon E5-2680 v4 (28 cores, 56 threads)
Motherboard	MOUGOL X99
RAM	8 GB DDR4
GPU	NVIDIA GeForce RTX 3050 Low Profile
Video Memory (VRAM)	6 GB

To evaluate the performance of the neural network architectures, multiple evaluation metrics were employed, with particular emphasis on the *Word Error Rate* (WER) and the *Character Error Rate* (CER). In addition to these metrics, the training and validation loss and accuracy were monitored throughout each training epoch, enabling the learning progression of the models to be analyzed.

The analysis of these metrics makes it possible not only to assess the models' ability to recognize words and characters but also to identify learning trends, including potential periods of stagnation or convergence. Consequently, it provides insights into how the characteristics of the datasets influence the performance of the different architectures, helping to identify the factors that improve or limit their recognition capabilities.

Within this context, the objective of this study is to evaluate, under a controlled experimental setting, four neural network architectures for handwritten medical prescription recognition. Furthermore, the study aims to investigate how the characteristics of the selected datasets

influence the performance of each architecture by analyzing the factors that contribute to improvements or reductions in recognition performance across different datasets.

2 Related Work

Apresente os trabalhos mais relevantes e explique como este artigo se diferencia da literatura. Use citações no formato [**?**] ou **?**].

3 Method

To ensure a fair comparison among all models, the same training configuration was adopted for every architecture. This approach enabled a consistent and unbiased benchmark across all evaluated models. To achieve this, a standardized training protocol was developed, in which all architectures were trained using the same settings, including the number of epochs, learning rate, and batch size. This protocol sought to minimize the influence of external factors on the training process, ensuring that the observed differences in performance were predominantly attributable to the characteristics of the evaluated architectures and datasets. Consequently, the comparison became more consistent, reliable, and representative of each model's actual performance.

At the end of the training process, the obtained results were consolidated through different evaluation procedures. To this end, tables containing the main performance metrics throughout the training process were generated, and the best-performing model across all training epochs was saved. Subsequently, this model was evaluated to obtain the final performance metrics, enabling a consistent assessment of its generalization capability. This approach provided a reliable basis for comparing the evaluated architectures.

3.1 Proposed Approach

The adopted methodology for comparing the models consisted of standardizing all experimental stages to ensure equivalent evaluation conditions. First, the dataset was preprocessed, including its organization and partitioning into training, validation, and test splits. Next, the models were implemented in Python and trained using the same hyperparameters, ensuring that performance differences were attributable to the evaluated architectures rather than training configurations. Finally, the models were evaluated using the test set, enabling a systematic comparison of the obtained results.

1. **Initializing the models:** Each architecture was configured with its respective parameters and output vocabulary. For transformer-based models, pre-trained checkpoints were used as the initial weights, whereas the remaining architectures were initialized with their default settings.

2. **Processamento dos dados:** as imagens foram convertidas para escala de cinza, redimensionadas para altura de 64 pixels, com largura máxima de 512 pixels, preservando-se a razão de aspecto e aplicando-se preenchimento quando necessário. Os rótulos textuais foram normalizados por meio da remoção de espaços excedentes e conversão para letras minúsculas. Os dados foram organizados em conjuntos fixos de treinamento, validação e teste.

3. **Otimização:** o treinamento foi realizado em *batches*, utilizando o otimizador AdamW. A função de perda foi definida de acordo com a estratégia de predição de cada arquitetura, incluindo perda por entropia cruzada, CTC ou perda baseada em permutações. Ao final de cada época, o desempenho no conjunto de validação foi monitorado para selecionar o melhor *checkpoint*.

4. **Avaliação:** o melhor *checkpoint* selecionado na validação foi aplicado exclusivamente ao conjunto de teste. O desempenho foi quantificado por acurácia de correspondência exata, *Character Error Rate* (CER) e *Word Error Rate* (WER), permitindo avaliar tanto a correção integral das predições quanto os erros em nível de caracteres e palavras.

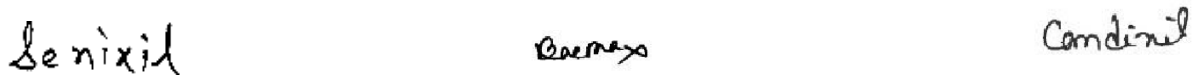
4 Experimental Setup

4.1 Datasets and Preprocessing

O *Doctor's Handwritten Prescription BD Dataset* (*PrescriptionBD*) foi desenvolvido por pesquisadores de Bangladesh com o propósito de disponibilizar um conjunto de dados público voltado ao reconhecimento de prescrições médicas manuscritas [4]. O desenvolvimento do dataset foi motivado pela limitada disponibilidade de bases públicas para o treinamento e a avaliação de modelos de reconhecimento de escrita manuscrita aplicados ao contexto médico. Para sua construção, foram coletadas prescrições médicas reais provenientes de Bangladesh, das quais palavras individuais foram segmentadas e posteriormente anotadas para compor o conjunto de dados. Ao final do processo, o dataset foi disponibilizado publicamente, possibilitando sua utilização em pesquisas relacionadas ao reconhecimento óptico de caracteres (OCR), ao reconhecimento de texto manuscrito (HTR) e a aplicações de inteligência artificial na área da saúde.

A construção do *PrescriptionBD* envolveu procedimentos de segmentação, rotulação e classificação das palavras extraídas das prescrições médicas, resultando em um conjunto de dados organizado e apropriado para o treinamento e a avaliação de modelos de reconhecimento de escrita manuscrita. As amostras apresentam, em geral, boa qualidade visual, com níveis de nitidez que favorecem a extração de características pelas arquiteturas de aprendizado profundo.

Na Figura 2 são apresentadas algumas amostras do *PrescriptionBD*. Observa-se que o dataset possui imagens com resoluções variáveis, tanto em altura quanto em largura, tornando necessária a realização de uma etapa de padronização para um tamanho único antes do treinamento das redes neurais. Além disso, o *PrescriptionBD* já disponibiliza uma divisão oficial dos dados em conjuntos de treinamento e teste (*train/test split*), característica que contribui para a reprodutibilidade dos experimentos e permite a comparação consistente entre diferentes abordagens.



(a) (b) (c)

Figura 2: Amostras do PrescriptionBD

O RxHandBD é um conjunto de dados desenvolvido por Md. Masudul Islam, da Bangladesh University of Business and Technology (BUBT) [2], e disponibilizado publicamente por meio dos repositórios Zenodo e Mendeley Data. O dataset foi criado com o objetivo de fornecer um benchmark padronizado para pesquisas em reconhecimento de escrita manuscrita (HTR) e reconhecimento óptico de caracteres (OCR) aplicados a prescrições médicas manuscritas.

A documentação do *RxHandBD* informa que as amostras foram obtidas a partir de prescrições médicas físicas, das quais palavras individuais foram segmentadas e posteriormente anotadas. No entanto, a documentação disponibilizada não fornece informações detalhadas sobre o processo de aquisição das prescrições, o número de profissionais participantes da coleta, nem os procedimentos empregados para digitalização e segmentação das amostras. O dataset é composto por 5.578 imagens de palavras extraídas de prescrições médicas manuscritas, correspondentes a 1.559 palavras distintas. As imagens são disponibilizadas no formato JPG, enquanto suas respectivas anotações são fornecidas em arquivos CSV.

O *RxHandBD* foi selecionado neste estudo por disponibilizar um conjunto padronizado de

palavras provenientes de prescrições médicas manuscritas, contendo transcrições anotadas e uma divisão oficial entre os conjuntos de treinamento e teste. Em comparação ao *PrescriptionBD*, esse dataset apresenta características como maior espessura dos traços das letras e maior expressão da variabilidade regional das caligrafias presentes em prescrições médicas. Essas diferenças tornam o *RxHandBD* um recurso relevante para avaliar a capacidade de generalização dos modelos em cenários com diferentes padrões de escrita manuscrita. Sob uma perspectiva comparativa, é de interesse investigar o desempenho das arquiteturas diante de materiais de escrita com características distintas. Essas particularidades podem ser observadas na Figura 3, que ilustra exemplos representativos das características caligráficas presentes no dataset.



(a) (b) (c)

Figura 3: Amostras do RxHandBD

Conforme discutido anteriormente, o *PrescriptionBD* apresenta imagens com resoluções não padronizadas, cujas dimensões variam tanto em altura quanto em largura. Para garantir a uniformidade do conjunto de dados e possibilitar uma comparação direta com o *RxHandBD*, adotou-se a resolução de (512×512) pixels como padrão de entrada para todas as arquiteturas avaliadas. Essa padronização também se faz necessária para a conversão das imagens em tensores de dimensões fixas, requisito fundamental para o treinamento das redes neurais.

Para preservar integralmente o conteúdo das prescrições e evitar distorções geométricas decorrentes de redimensionamentos não proporcionais, optou-se pela técnica de extensão em branco (*padding*). Nesse procedimento, cada imagem foi posicionada sobre um fundo branco até atingir a resolução de (512×512) pixels, mantendo suas proporções originais e adicionando apenas pixels de preenchimento nas regiões excedentes. Dessa forma, todas as amostras passaram a apresentar dimensões uniformes, tornando-se adequadas para o processamento pelas arquiteturas de aprendizado profundo e permitindo uma comparação metodológica mais justa entre os datasets. Na Figura 4 é possivel ver uma comparação entre imagens antes da padronização e após a padronização, Figura 4a é possivel ver a prescrição do medicamento Lenixil em 103×30 e na Figura 4b após a padronização em 512×512.



(a) (b)

Figura 4: Exemplos de imagens do *PrescriptionBD* após a padronização para resolução de 512×512 pixels.

Para a realização dos experimentos, foram considerados três cenários distintos: treinamento e avaliação utilizando exclusivamente o *PrescriptionBD*, treinamento e avaliação utilizando exclusivamente o *RxHandBD*, e um cenário adicional composto por um dataset combinado, formado pela união das amostras de ambos os conjuntos de dados. Para esse dataset combinado, foi realizada uma nova divisão entre os conjuntos de treinamento e teste, seguindo os *splits* apresentados na Tabela 2. No caso do *PrescriptionBD*, foi preservada a divisão oficial disponibilizada

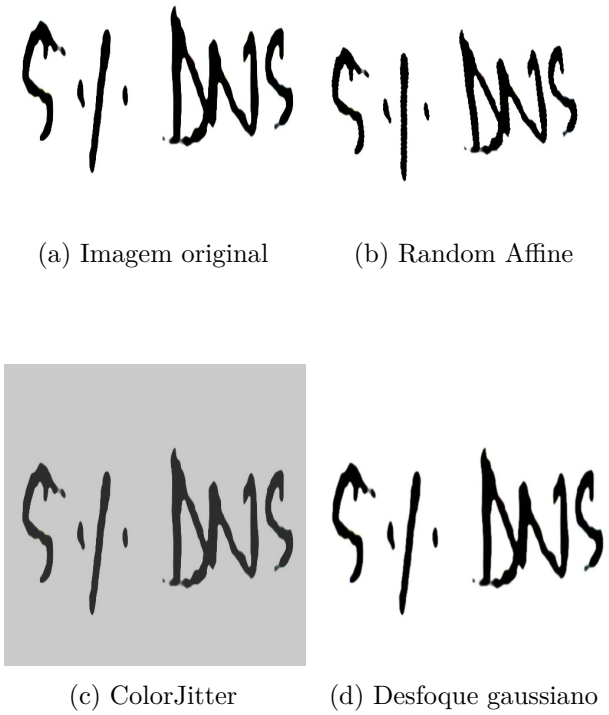
pelos autores, de modo a garantir a reprodutibilidade dos experimentos e a comparabilidade dos resultados.

Tabela 2: Splits utilizados nos diferentes cenários experimentais.

Cenário	**Train**	**Val**	**Test**	**Total**	**Método**
RxHandBD	3905	837	836	5578	70/15/15 por amostra, seed 757
PrescriptionBD	3120	780	780	4680	Split oficial preservado
Combinado	7025	1617	1616	10258	União dos splits correspondentes

Devido à limitada quantidade de amostras disponíveis para treinamento, empregou-se a técnica de *data augmentation* com o objetivo de aumentar a variabilidade dos dados e reduzir o risco de sobreajuste (*overfitting*) dos modelos. As transformações foram aplicadas de forma aleatória durante o treinamento, gerando diferentes variações de uma mesma imagem a cada época.

Foram utilizadas três técnicas de aumento de dados. A primeira consistiu na transformação *RandomAffine*, responsável por aplicar rotações e translações aleatórias às imagens, com probabilidade de 90%. A segunda foi a transformação *ColorJitter*, utilizada para modificar aleatoriamente o brilho e o contraste das imagens, com variação de 0,25 para o brilho e 0,35 para o contraste, sendo aplicada com probabilidade de 60%. Por fim, empregou-se a transformação *GaussianBlur*, que aplica um desfoque gaussiano utilizando *kernel* de tamanho 3 e valor de σ variando entre 0,1 e 0,8, com probabilidade de aplicação de 30%. Na Figura 5 é possivel visualizar o resultado da aplicação da metodologia de aumentação em uma amostra do conjunto de dados *RxHandBD*.



(a) Imagem original (b) Random Affine

(c) ColorJitter (d) Desfoque gaussiano

Figura 5: Exemplo das transformações de data augmentation aplicadas a uma amostra do conjunto de treinamento do RxHandBD.

Essas aplicações permitiram um treinamento dos dados mais conciso com menor ocorrência de over-fitting.

4.2 Computational Models

Para este projeto foram utilizado 4 arquiteturas, e são elas: Uma CNN baseline, CNN com Bilstm, Trocqr e o Parseq

4.2.1 CNN Baseline

As redes neurais convolucionais (*Convolutional Neural Networks* – CNNs) possuem inspiração em princípios observados no sistema visual biológico, especialmente nos estudos sobre o córtex visual realizados por Hubel e Wiesel [5]. Embora não representem uma reprodução fiel do funcionamento do cérebro humano, essas arquiteturas foram concebidas a partir da observação de que o sistema visual é capaz de reconhecer padrões complexos por meio da combinação hierárquica de características visuais simples.

Nos experimentos conduzidos por Hubel e Wiesel, observou-se que neurônios presentes no córtex visual respondem seletivamente a estímulos específicos, como bordas, orientações e contrastes. Além disso, verificou-se que o processamento da informação visual ocorre de forma hierárquica, na qual neurônios de níveis superiores integram informações extraídas por neurônios mais simples para representar estruturas cada vez mais complexas [5].

Inspiradas nesses princípios, as CNNs introduzem o conceito de campos receptivos locais por meio das camadas de convolução, nas quais filtros aprendem automaticamente padrões presentes nas imagens. À medida que múltiplas camadas convolucionais são empilhadas, torna-se possível construir representações hierárquicas das características visuais, iniciando pela detecção de elementos básicos, como bordas e texturas, e evoluindo para padrões mais complexos, como formas e objetos. Essa organização tornou as CNNs uma das principais arquiteturas para tarefas de visão computacional e reconhecimento de padrões.

Os modelos computacionais das CNNs, tal como são conhecidos atualmente, têm suas bases conceituais no trabalho de Fukushima, apresentado no artigo *Neocognitron: A Self-Organizing Neural Network Model for a Mechanism of Pattern Recognition Unaffected by Shift in Position* [6]. Nesse estudo foi proposta uma arquitetura hierárquica inspirada no córtex visual, composta por camadas responsáveis pela extração progressiva de características e pela obtenção de invariância a pequenas translações dos padrões de entrada. Embora o Neocognitron não utilizasse treinamento por *backpropagation*, seus princípios arquiteturais serviram de base para o desenvolvimento das CNNs modernas.

Posteriormente, LeCun et al. [7] consolidaram esse paradigma ao apresentar uma arquitetura convolucional treinada por *backpropagation* para reconhecimento óptico de caracteres (OCR), demonstrando que a aprendizagem automática de filtros convolucionais possibilitava elevados níveis de desempenho em tarefas de reconhecimento de padrões. Esse trabalho estabeleceu as bases práticas para a ampla adoção das CNNs em problemas de visão computacional.

Esta CNN foi utilizada neste projeto como um modelo de referência (*baseline*), representando o ponto de partida para a comparação entre as arquiteturas avaliadas. Seu emprego permite estabelecer um desempenho inicial para modelos convolucionais tradicionais em tarefas de reconhecimento de prescrições médicas manuscritas, servindo como base para a análise dos ganhos proporcionados por arquiteturas mais sofisticadas.

Entretanto, o problema abordado neste trabalho difere de uma tarefa convencional de classificação de imagens. O objetivo consiste em reconhecer palavras completas presentes nas prescrições, caracterizando um problema de reconhecimento de sequências. Uma CNN convencional realiza apenas uma única classificação para cada imagem de entrada, o que a impede de predizer diretamente todos os caracteres que compõem uma palavra em uma única inferência.

Para contornar essa limitação, a CNN *baseline* foi modelada como um classificador de palavras. Nessa abordagem, cada palavra presente no conjunto de treinamento é tratada como uma classe distinta. Consequentemente, a saída da rede corresponde a uma distribuição de probabilidades sobre todas as classes conhecidas, sendo selecionada como predição a palavra com maior probabilidade. Dessa forma, o modelo não realiza o reconhecimento sequencial dos caracteres, mas estima diretamente a qual palavra previamente aprendida a imagem de entrada pertence.

Como evolução da CNN *baseline*, foi desenvolvida uma arquitetura que incorpora uma camada *Bidirectional Long Short-Term Memory* (BiLSTM). Essa modificação permite que o modelo deixe de realizar apenas a classificação de palavras previamente conhecidas e passe a reconhecer a sequência de caracteres presente na imagem, tornando-o mais adequado para tarefas de reconhecimento de texto manuscrito.

4.2.2 CNN BiLSTM

Posteriormente, visando aumentar a precisão do reconhecimento, foi incorporado um módulo de *Bidirectional Long Short-Term Memory* (BiLSTM) à CNN baseline. Essa arquitetura consiste em uma rede neural recorrente capaz de modelar dependências sequenciais de longo alcance, processando a sequência simultaneamente nos sentidos direto e inverso [8]. Dessa forma, o modelo passa a considerar não apenas o elemento atual, mas também o contexto fornecido pelos caracteres anteriores e posteriores.

A inclusão do BiLSTM justifica-se pelo fato de palavras manuscritas apresentarem uma estrutura sequencial inerente. Em um idioma, determinados caracteres possuem maior probabilidade de ocorrer em conjunto, como a frequente alternância entre consoantes e vogais, além de padrões ortográficos característicos de cada palavra. Ao explorar essas dependências contextuais, o BiLSTM complementa as características visuais extraídas pela CNN, permitindo que a classificação considere tanto a aparência dos caracteres quanto a relação sequencial existente entre eles. Assim, a arquitetura CNN-BiLSTM foi avaliada quanto à sua capacidade de melhorar o reconhecimento de prescrições médicas manuscritas em comparação à CNN baseline.

Com a incorporação do BiLSTM, manteve-se a abordagem de reconhecimento baseada em um conjunto de classes previamente definidas. Embora a modelagem sequencial tenha proporcionado um melhor aproveitamento do contexto entre os caracteres, a arquitetura continuou limitada à classificação de palavras pertencentes às classes conhecidas durante o treinamento. Dessa forma, o problema de reconhecer palavras inéditas ou compostas por combinações arbitrárias de caracteres permaneceu presente.

Para superar essa limitação, foram posteriormente avaliadas arquiteturas baseadas em *Transformers*. Diferentemente da abordagem de classificação por classes, esses modelos realizam o reconhecimento em nível de sequência de caracteres. Assim, tornam-se capazes de reconhecer palavras que não estavam presentes no conjunto de treinamento.

4.2.3 Trocqr

4.2.4 Parseq

4.3 Baselines and Metrics

Para a realização das comparações entre as arquiteturas, foi inicialmente definida uma matriz de experimentos, responsável por estabelecer os conjuntos de treinamento e de teste utilizados em cada modelo. Essa padronização permitiu conduzir avaliações sistemáticas por meio de métricas consistentes, possibilitando analisar o desempenho de cada arquitetura e compreender os fatores que influenciaram os resultados obtidos. Ao final, os resultados de todos os experimentos foram comparados entre si.

Com o objetivo de garantir uma comparação justa entre as arquiteturas, foram definidas matrizes de comparação específicas para cada conjunto de experimentos. Essas matrizes consideram as diferenças conceituais entre os modelos, bem como suas particularidades de treinamento, evitando comparações inadequadas entre abordagens distintas. Dessa forma, foi possível avaliar a capacidade de generalização e o desempenho de cada arquitetura em diferentes cenários e quantidades de dados disponíveis para treinamento.

É possivel visualizar todos os experiemntos na Tabela 3.

Tabela 3: Matriz de experimentos por arquitetura e conjunto de dados.

Exp.	Arquitetura	Dataset	Treino	Validação	Teste
E1	CNN baseline	PrescriptionBD	3120	780	780
E1	CNN baseline	RxHandBD	3905	837	836
E1	CNN baseline	Combinado	7025	1617	1616
E2	CNN-BiLSTM	PrescriptionBD	3120	780	780
E2	CNN-BiLSTM	RxHandBD	3905	837	836
E2	CNN-BiLSTM	Combinado	7025	1617	1616
E3	TrOCR	PrescriptionBD	3120	780	780
E3	TrOCR	RxHandBD	3905	837	836
E3	TrOCR	Combinado	7025	1617	1616
E4	PARSeq	PrescriptionBD	3120	780	780
E4	PARSeq	RxHandBD	3905	837	836
E4	PARSeq	Combinado	7025	1617	1616

Ao longo de todo o processo de treinamento foram coletadas métricas referentes ao desempenho do modelo em cada época, com o objetivo de compreender a evolução do aprendizado durante o treinamento. Para isso, foram registrados os valores da função de perda (*loss*) nos conjuntos de treinamento e validação, bem como a acurácia obtida em ambos os conjuntos.

Para a avaliação dos modelos, foram utilizadas métricas capazes de analisar diferentes aspectos do desempenho no reconhecimento de texto. A acurácia foi empregada para medir a capacidade do modelo de reconhecer corretamente toda a sequência de caracteres presente em uma imagem. Além disso, foi utilizada a métrica *Character Error Rate* (CER), que quantifica a taxa de erros em nível de caractere, indicando o número de inserções, deleções e substituições necessárias para transformar a predição no texto de referência. Complementarmente, foi utilizada a métrica *Word Error Rate* (WER), que avalia os erros em nível de palavra, medindo a quantidade de palavras reconhecidas incorretamente em relação ao texto esperado.

4.4 Implementation Details

Os experimentos foram implementados em Python utilizando o pacote desenvolvido neste projeto, denominado `med-ocr-research`. O ambiente de execução utiliza Python 3.10 ou superior e tem como principal framework de aprendizado profundo o PyTorch. Todos os treinamentos foram executados com aceleração CUDA em uma GPU NVIDIA GeForce RTX 3050 com 6 GB de memória. A configuração completa do ambiente computacional pode ser visualizada na Tabela 1.

As principais dependências utilizadas durante o desenvolvimento são apresentadas na Tabela 4. Os valores apresentados representam as versões mínimas utilizadas no ambiente experimental. Para o TrOCR, os arquivos do modelo pré-treinado registram a utilização da biblioteca Transformers na versão 5.12.1.

Durante todos os experimentos foi utilizada a semente aleatória 42 para garantir a reprodutibilidade dos resultados. Essa semente foi aplicada aos geradores das bibliotecas `random`, NumPy e PyTorch, incluindo a inicialização da CUDA por meio de `torch.cuda.manual_seed_all`. Para a organização dos datasets foi preservado o split oficial do PrescriptionBD. Já para o RxHandBD, foi realizada uma divisão de 70% para treinamento, 15% para validação e 15% para teste, utilizando a semente derivada 757. O dataset combinado foi obtido por meio da união dos respectivos subconjuntos dos dois datasets.

A CNN Baseline e a CNN-BiLSTM foram implementadas computacionalmente neste projeto. Para o TrOCR foi utilizado o checkpoint pré-treinado `microsoft/trocr-small-handwritten`. Já para o PARSeq foi utilizada a implementação disponibilizada no repositório `baudm/parseq`,

Tabela 4: Dependências de software utilizadas no ambiente experimental.

Biblioteca	**Versão**	**Biblioteca**	**Versão**
Python	≥ 3.10	PyTorch	≥ 2.2
Torchvision	≥ 0.17	Transformers	5.12.1
NumPy	≥ 1.24	Pandas	≥ 2.0
Pillow	≥ 10.0	Timm	≥ 1.0
PyTorch Lightning	≥ 2.2	Accelerate	≥ 0.30
Albumentations	≥ 1.4	SentencePiece	$\geq 0.2.1$
NLTK	≥ 3.8	Tqdm	≥ 4.66
PyYAML	≥ 6.0	Protobuf	≥ 4.25

fixada no commit `1902db043c029a7e03a3818c616c06600af574be`. Todo o código-fonte desenvolvido, bem como as configurações experimentais e os scripts de avaliação, estão disponíveis no repositório do projeto:

`https://github.com/SamuelFerrc/Medical-Handwriting-Ocr`

5 Results and Discussion

Esta seção reúne os resultados das doze avaliações realizadas: quatro famílias de modelos, cada uma avaliada nos datasets PrescriptionBD, RxHandBD e no cenário combinado. A ordem foi organizada para permitir a discussão em três níveis: (i) comparação agregada entre modelos, (ii) efeito do dataset e (iii) análise diagnóstica de cada avaliação. As métricas foram recalculadas diretamente a partir dos arquivos de predições avaliadas. As tabelas detalhadas permanecem disponíveis na pasta de artefatos para consulta, mas não são inseridas no artigo principal para manter a seção de resultados concisa.

5.1 Overall comparison

A comparação agregada por modelo e cenário é apresentada nas Figuras 6, 7 e 8, que mostram, respectivamente, a acurácia de correspondência exata, o CER e o WER para as doze avaliações.

Além dos gráficos, a Tabela 5 apresenta as métricas agregadas de cada modelo e cenário em formato compacto.

Tabela 5: Evaluation summary by model and scenario

Model	**Scenario**	**N**	**Correct**	**Accuracy**	**CER**	**WER**	**Mean confidence**
CNN	PrescriptionBD	780	322	0.4128	0.5328	0.5911	0.2728
CNN	RxHandBD	836	262	0.3134	0.5866	0.7313	0.2831
CNN	Combined	1616	463	0.2865	0.6467	0.7412	0.2458
CNN-BiLSTM	PrescriptionBD	780	527	0.6756	0.1868	0.3278	0.9822
CNN-BiLSTM	RxHandBD	836	436	0.5215	0.1811	0.4984	0.9767
CNN-BiLSTM	Combined	1616	927	0.5736	0.2064	0.4370	0.9823
TrOCR	PrescriptionBD	780	693	0.8885	0.0864	0.1127	0.9886
TrOCR	RxHandBD	836	612	0.7321	0.1122	0.2824	0.9745
TrOCR	Combined	1616	1307	0.8088	0.1024	0.2018	0.9826
PARSeq	PrescriptionBD	780	703	0.9013	0.0680	0.1000	0.9649
PARSeq	RxHandBD	836	579	0.6926	0.1067	0.3130	0.8880
PARSeq	Combined	1616	1270	0.7859	0.0943	0.2214	0.9344

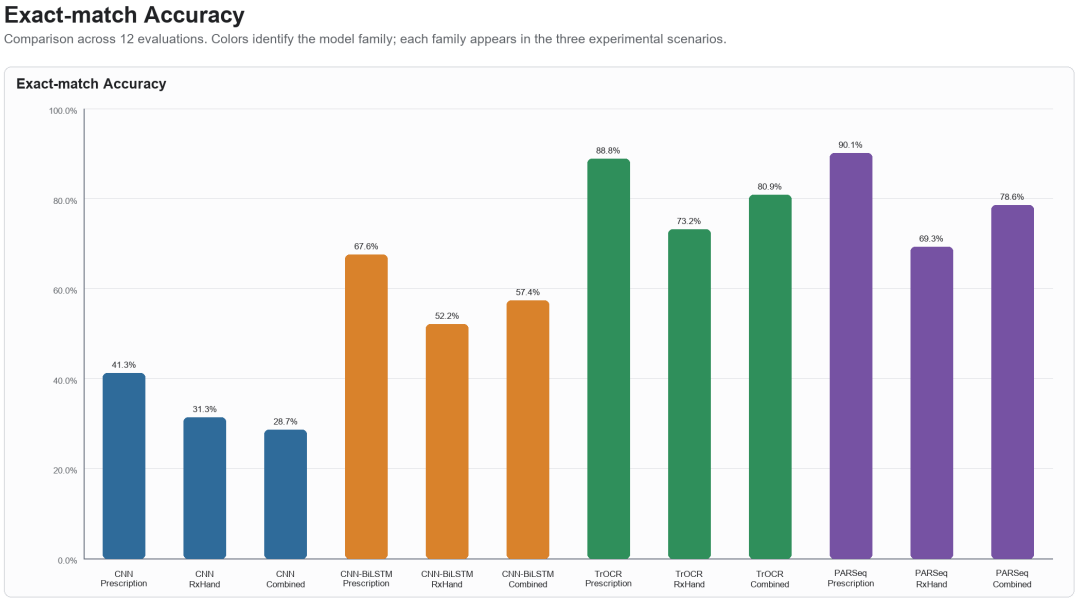


Figura 6: Exact-match accuracy across all twelve evaluations.

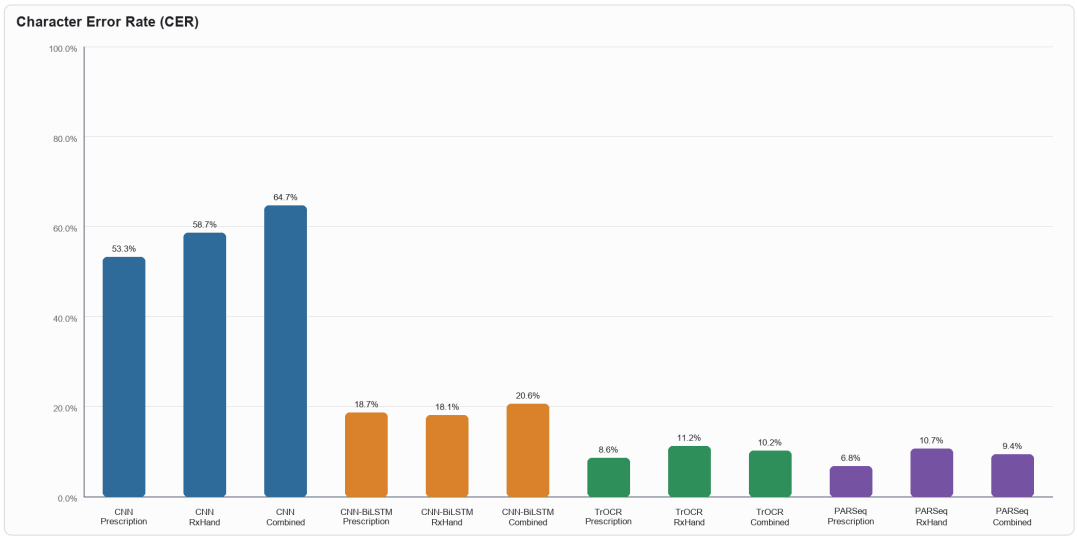


Figura 7: Character Error Rate (CER) across all twelve evaluations.

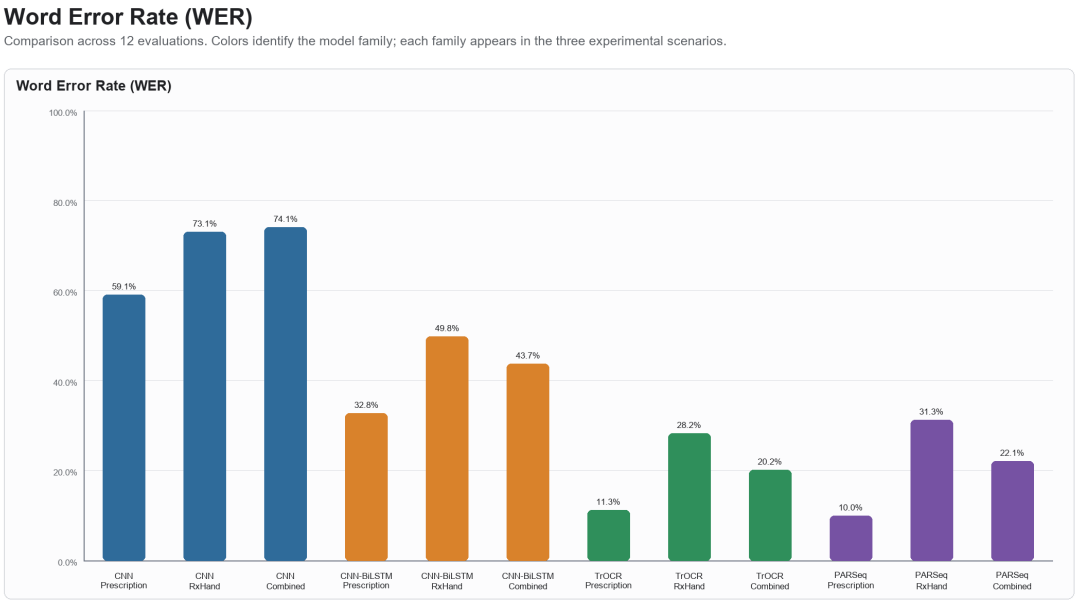


Figura 8: Word Error Rate (WER) across all twelve evaluations.

Os resultados vistos na Figura 6 demonstraram que os modelos apresentaram unanimemente melhor desempenho no conjunto de dados PrescriptionBD. Esse comportamento, entretanto, não foi observado no RxHandBD, no qual a maioria dos modelos obteve desempenho inferior, com exceção da CNN Baseline, que apresentou resultados relativamente mais consistentes.

Essa diferença pode ser atribuída principalmente às características visuais de cada conjunto de dados. Conforme ilustrado na Figura 3, as imagens do RxHandBD apresentam traços mais espessos, borrados e com menor definição, dificultando a extração de características discriminativas tanto pelas CNNs quanto pelos modelos baseados em Transformers. Em contrapartida, a Figura 2 mostra que o PrescriptionBD possui caracteres com traços mais finos, contínuos e bem definidos, favorecendo a identificação de padrões e a aprendizagem de representações mais robustas pelas redes neurais. Consequentemente, as diferenças na qualidade visual dos conjuntos de dados exerceram influência direta no desempenho dos modelos durante o treinamento e a inferência.

Por sua vez, os experimentos realizados sobre o conjunto de dados combinado apresentaram desempenho intermediário em relação aos dois conjuntos originais. Esse comportamento era esperado, uma vez que o conjunto combinado reúne simultaneamente as características favoráveis do PrescriptionBD e os desafios presentes no RxHandBD. Dessa forma, os modelos foram expostos tanto a exemplos de maior qualidade quanto a amostras com maior complexidade visual, resultando em um desempenho médio entre os dois cenários avaliados.

Uma característica notável foi que a CNN-BiLSTM apresentou um CER menor no conjunto de dados RxHandBD do que no PrescriptionBD, conforme observado na Figura 7. Esse resultado indica que, apesar de o RxHandBD representar um conjunto de dados mais desafiador para a maioria dos modelos avaliados, a arquitetura CNN-BiLSTM foi capaz de reconhecer os caracteres individuais com maior precisão nesse cenário específico.

Em todos os modelos e conjuntos de dados avaliados, o WER apresentou comportamento consistente com a acurácia geral, conforme ilustrado na Figura 8. De maneira geral, modelos que obtiveram maiores valores de acurácia também apresentaram menores valores de WER, evidenciando uma relação inversa entre essas métricas e reforçando a consistência dos resultados experimentais.

5.2 Dataset-specific comparison

Para separar o efeito do cenário combinado do efeito da arquitetura, a Figura 9 apresenta visualmente, por dataset, a comparação de acurácia, CER e WER.

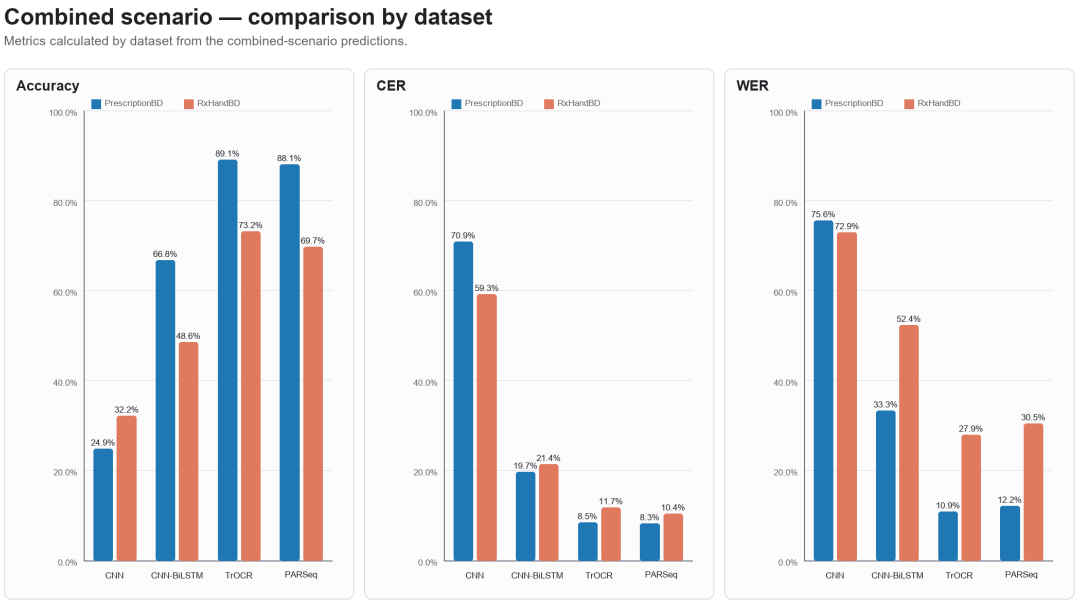


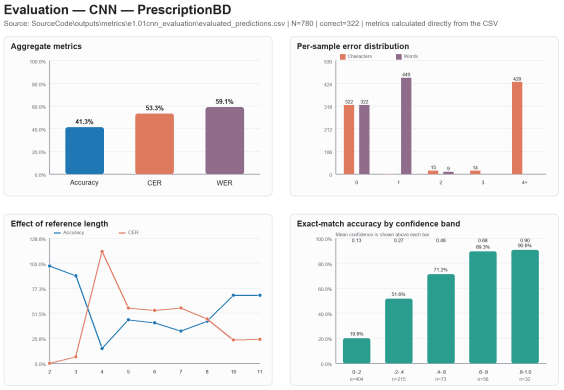
Figura 9: Comparison of the combined scenario by dataset.

Para cada modelo de rede neural, foi calculada a diferença entre os resultados representados pelas barras azul e laranja, em relação a acurácia geral. A CNN Baseline foi o único modelo em que a barra laranja apresentou desempenho superior à barra azul, com uma diferença de 7,3 pontos percentuais. Nos demais modelos, a barra azul obteve desempenho superior, apresentando diferenças de 18,2 pontos percentuais para a CNN-BiLSTM, 15,9 pontos percentuais para o TrOCR e 18,4 pontos percentuais para o PARSeq.

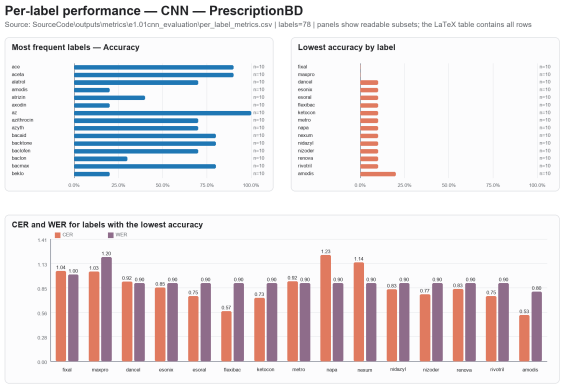
5.3 Per-evaluation diagnostic views

As figuras desta subseção complementam as métricas agregadas. Cada painel de predições avaliadas reúne distribuição de erros, relação entre desempenho e comprimento da referência e acurácia por faixa de confiança. O painel por rótulo mostra a distribuição de desempenho entre palavras, destacando os rótulos mais frequentes e os rótulos com menor acurácia. Esses painéis são descritivos e devem ser usados para investigar padrões de erro, não como substitutos das métricas agregadas.

5.3.1 CNN baseline

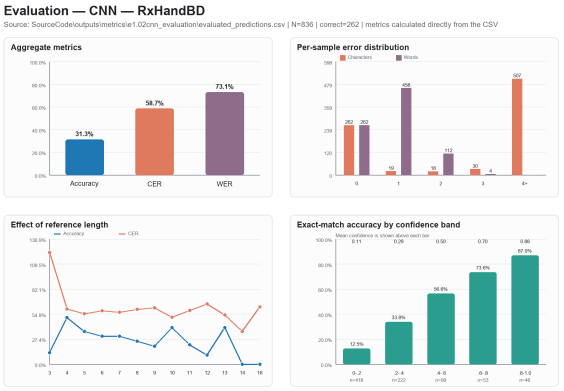


(a) Evaluated predictions.

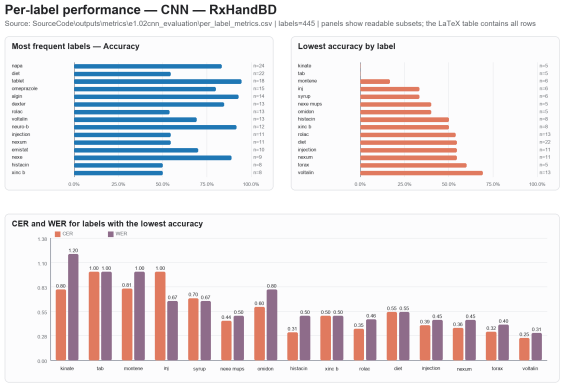


(b) Per-label metrics.

Figura 10: CNN baseline evaluated on PrescriptionBD.

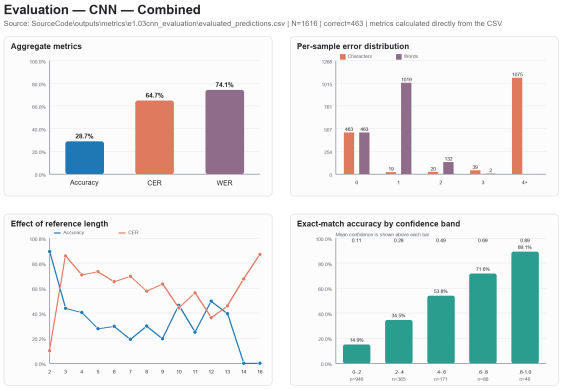


(a) Evaluated predictions.

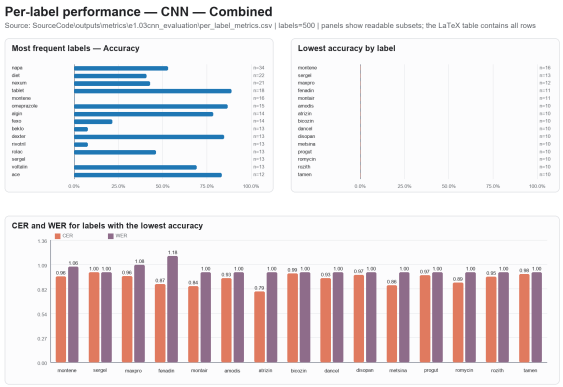


(b) Per-label metrics.

Figura 11: CNN baseline evaluated on RxHandBD.



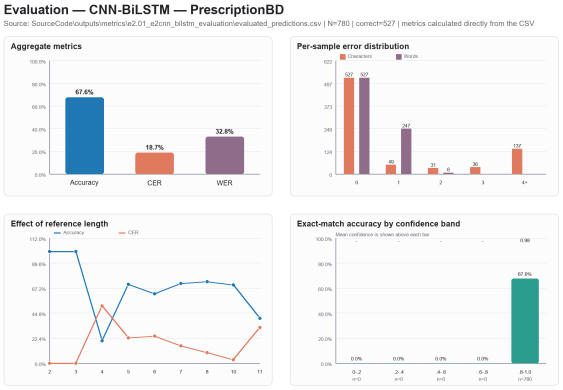
(a) Evaluated predictions.



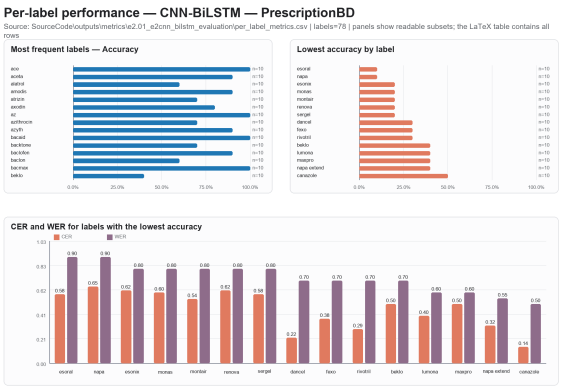
(b) Per-label metrics.

Figura 12: CNN baseline evaluated in the combined scenario.

5.3.2 CNN-BiLSTM

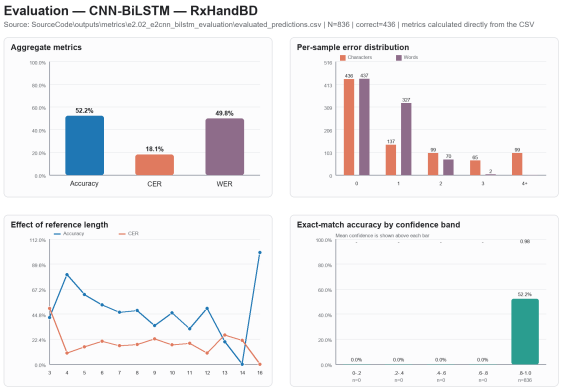


(a) Evaluated predictions.

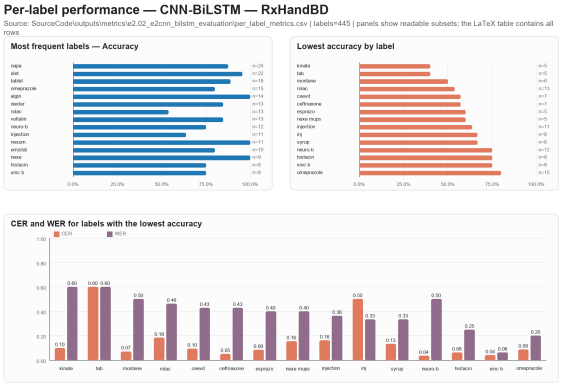


(b) Per-label metrics.

Figura 13: CNN-BiLSTM evaluated on PrescriptionBD.

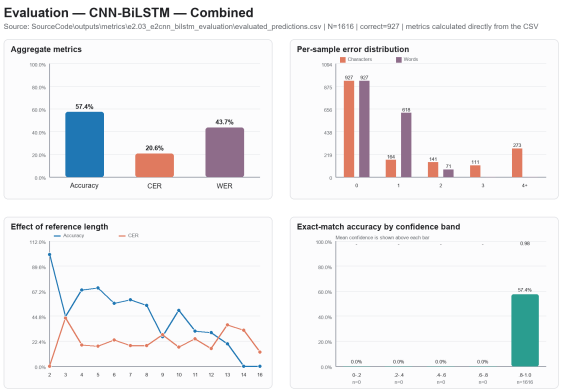


(a) Evaluated predictions.

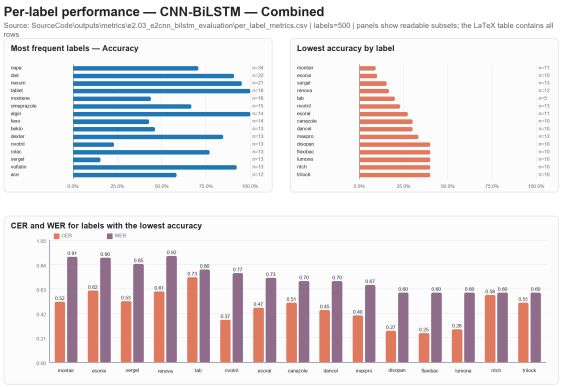


(b) Per-label metrics.

Figura 14: CNN-BiLSTM evaluated on RxHandBD.



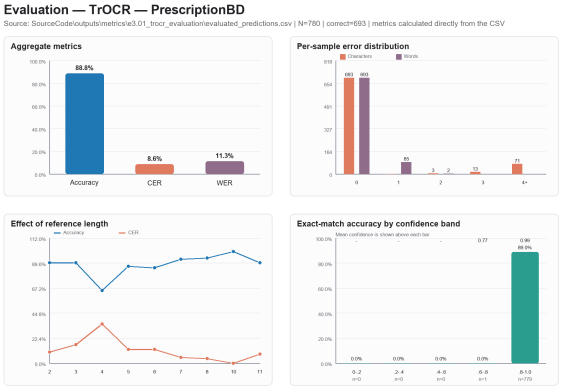
(a) Evaluated predictions.



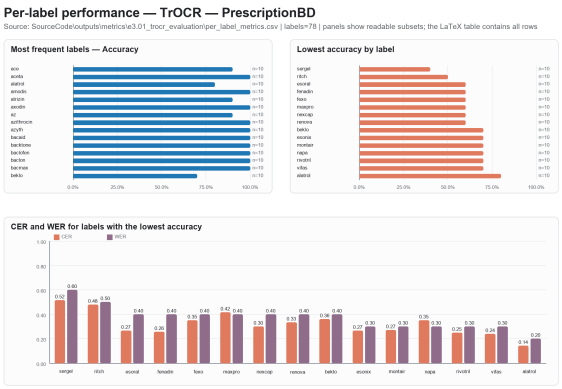
(b) Per-label metrics.

Figura 15: CNN-BiLSTM evaluated in the combined scenario.

5.3.3 TrOCR

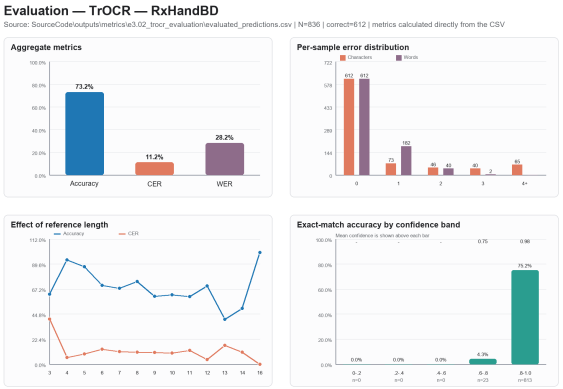


(a) Evaluated predictions.

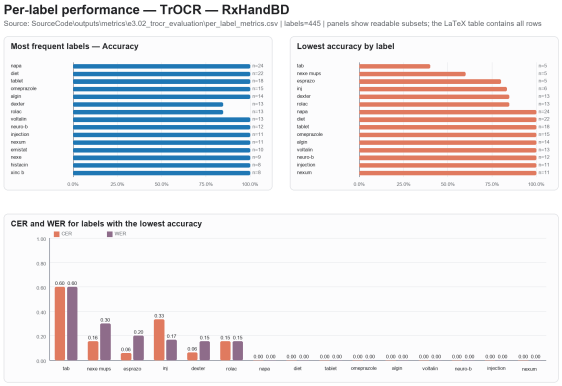


(b) Per-label metrics.

Figura 16: TrOCR evaluated on PrescriptionBD.

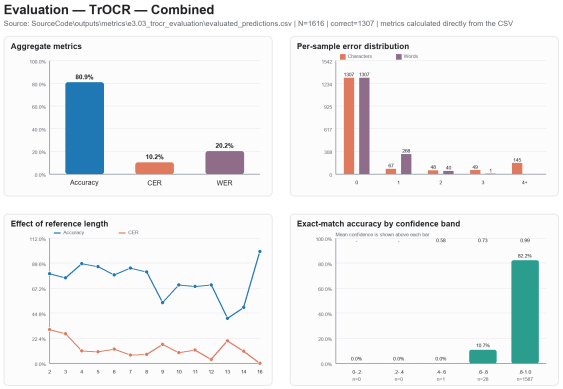


(a) Evaluated predictions.

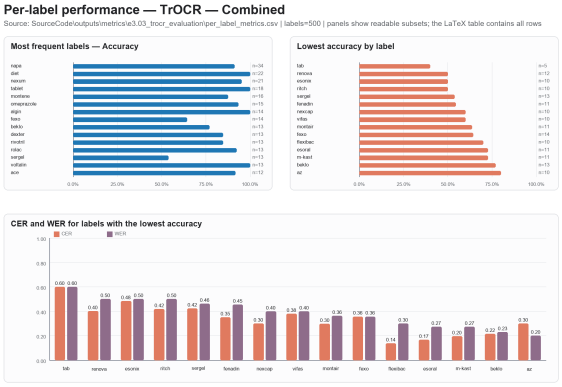


(b) Per-label metrics.

Figura 17: TrOCR evaluated on RxHandBD.



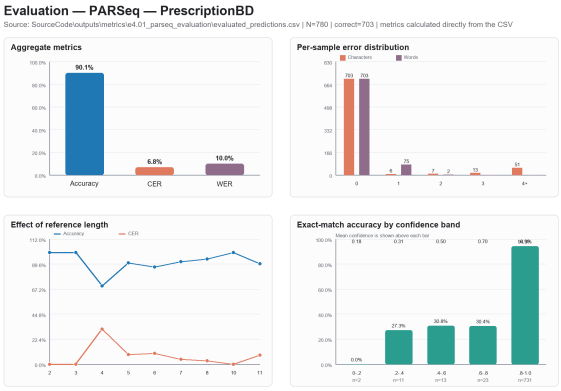
(a) Evaluated predictions.



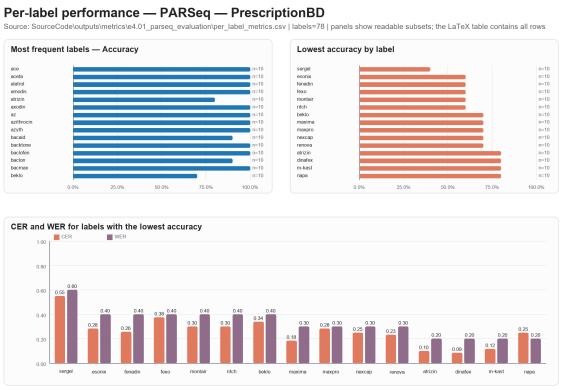
(b) Per-label metrics.

Figura 18: TrOCR evaluated in the combined scenario.

5.3.4 PARSeq

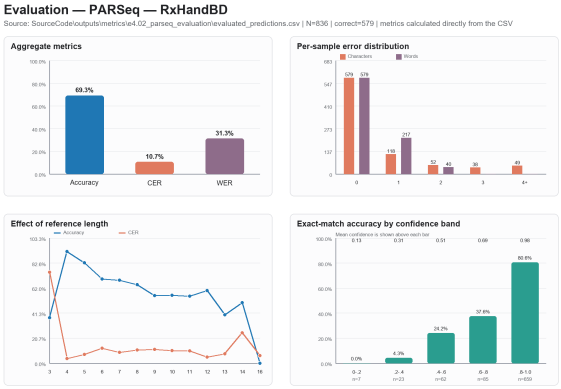


(a) Evaluated predictions.

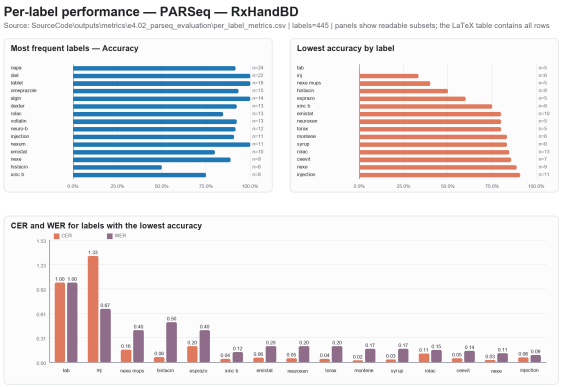


(b) Per-label metrics.

Figura 19: PARSeq evaluated on PrescriptionBD.

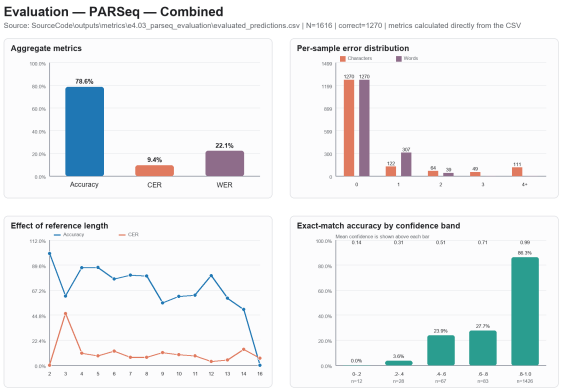


(a) Evaluated predictions.

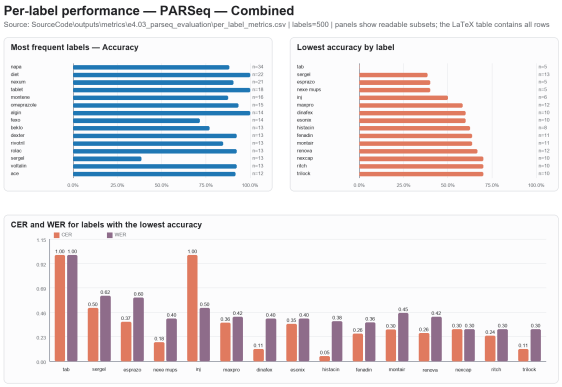


(b) Per-label metrics.

Figura 20: PARSeq evaluated on RxHandBD.



(a) Evaluated predictions.



(b) Per-label metrics.

Figura 21: PARSeq evaluated in the combined scenario.

6 Limitations

Este trabalho apresentou limitações relacionadas à quantidade de dados utilizada e ao tamanho dos *batches* de treinamento, restritos pela capacidade de memória disponível. Essas limitações podem ter introduzido algum viés nos resultados obtidos. Entretanto, todos os modelos foram treinados e avaliados sob as mesmas condições experimentais, utilizando o mesmo ambiente computacional e configurações de treinamento, de forma a garantir a maior equidade possível na comparação entre os métodos.

7 Conclusion

Os resultados obtidos evidenciam o potencial dos modelos de reconhecimento sequencial para a transcrição de palavras manuscritas em prescrições médicas. Em particular, TrOCR e PARSeq alcançaram os melhores desempenhos entre os métodos avaliados, com vantagens consistentes em relação à CNN baseline nos três cenários experimentais. O PARSeq destacou-se no PrescriptionBD, atingindo 90,13% de acurácia, CER de 0,0680 e WER de 0,1000, enquanto o TrOCR apresentou o melhor desempenho global no cenário combinado em acurácia (80,88%) e WER (0,2018). Esses resultados mostram que o uso de modelos pré-treinados, adaptados por *fine-tuning*, constitui uma estratégia eficaz para OCR de escrita médica manuscrita mesmo em um cenário de disponibilidade limitada de dados.

Code and Data Availability

O código, os dados e os materiais suplementares estão disponíveis em: `https://github.com/SamuelFerrc/Medical-Handwriting-Ocr`.

Referências

[1] Usman Ali, Sahil Ranmbail, Muhammad Nadeem, Hamid Ishfaq, Muhammad Umer Ramzan, and Waqas Ali. Leveraging deep learning with multi-head attention for accurate extraction of medicine from handwritten prescriptions, 2024. URL `https://doi.org/10.48550/arXiv.2412.18199`.

[2] Md Masudul Islam. RxHandBD: A handwritten prescription word image dataset. Mendeley Data, 2026. Version 3.

[3] Abdur Rahim Mia, Abdullah Al Mamun, Abdullah Al Sajid, and Aurunave Mollik Ruddra. Doctor's handwritten prescription BD dataset. Kaggle, 2024. URL `https://www.kaggle.com/dsv/8378585`.

[4] A. R. Mia, M. A.-A.-S. Chowdhury, A. A. Mamun, A. M. Ruddra, and N. T. Tanny. A deep neural network approach with pioneering local dataset to recognize doctor's handwritten prescription in bangladesh. In *2024 International Conference on Advances in Computing, Communication, Electrical, and Smart Systems (iCACCESS)*, Dhaka, Bangladesh, 2024.

[5] David H. Hubel and Torsten N. Wiesel. Receptive fields, binocular interaction and functional architecture in the cat's visual cortex. 1962.

[6] Kunihiko Fukushima. Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position. *Biological Cybernetics*, 36(4):193–202, 1980. doi: 10.1007/BF00344251.

[7] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998. doi: 10.1109/5.726791.

[8] Baoguang Shi, Xiang Bai, and Cong Yao. An end-to-end trainable neural network for image-based sequence recognition and its application to scene text recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 2564–2572, 2016. doi: 10.1109/CVPR.2016.277.