Comparative Benchmarking of Neural OCR Methods for Handwritten Word Recognition in Medical Prescription Images under Limited-Data and Computational Constraints

Samuel F. Santos*
Universidade Estadual de Santa Cruz

Abstract

This study presents a practical comparison of CNN-based and Transformer-based models for handwritten word recognition in medical prescription images. Two source datasets, RxHandBD and Doctor's Handwritten PrescriptionBD, were evaluated individually and in a combined training scenario. From-scratch training was used for a CNN baseline formulated as a closed-set word classifier and for a CNN-BiLSTM sequence-recognition model, whereas the pre-trained TrOCR and PARSeq Transformers were fine-tuned for character-sequence transcription. The study examines how dataset characteristics, training regimes, and task formulations affect recognition performance, model limitations, and training cost under limited-data conditions.

Keywords: Neural Networks; Convolution; Transformers; Artificial Intelligence.

1 Introduction

During medical appointments, patients are often issued a medical prescription containing information about medications and treatment instructions intended to support their recovery. However, the readability of these prescriptions is frequently affected by the physician's handwriting and the context in which they are written. Factors such as the urgency of medical care and the high demand for patient consultations can negatively impact the legibility of handwritten prescriptions, making their interpretation more challenging for both healthcare professionals and patients.

As a consequence, medical prescriptions often present low legibility, making their interpretation challenging for both pharmacists and patients. This difficulty has led several countries to adopt digital prescription systems as a way to reduce interpretation errors and improve patient safety. However, this transition has not occurred universally, and handwritten prescriptions are still widely used in many healthcare settings.

Therefore, it is important to investigate and understand the challenges of applying Optical Character Recognition (OCR) to handwritten medical prescriptions, including both textual characters and medical symbols. Furthermore, it is relevant to evaluate whether the knowledge and techniques developed for this domain can be generalized to other types of handwritten documents.

It is understood that handwritten manuscripts exhibit several characteristics relevant to this study, as they are composed of simplified geometric shapes and structural patterns that can be interpreted from the symbols present in the writing. Figures 1a and 1b illustrate these fundamental shapes while also highlighting the presence of noise and irregularities resulting from environmental conditions and the writing process, as previously discussed. Consequently, these

*E-mail: sfsantos.cic@uesc.br

images provide an appropriate basis for investigating complex geometric patterns, offering a representative depiction of the structural characteristics inherent to handwriting.



(a) (b)

Figure 1: Geometric Characteristics of Handwritten Medical Prescriptions

In the context of neural networks, it is important to evaluate the ability of different architectures to learn and recognize handwriting structures. This motivation is justified by the possibility of automatically classifying medical prescriptions and by the potential to use these structures as a basis for learning robust representations applicable to problems involving more complex geometric patterns, as demonstrated in [1].

The characteristics present in handwritten medical prescriptions are particularly relevant for model training because they reflect the natural variability introduced during the handwriting process. Furthermore, handwritten prescriptions incorporate variations arising from the writing process, the writer's individual style, and external influences. This differs from synthetic data, which generally exhibit more controlled patterns and lower variability.

Consequently, these characteristics play an important role in neural network training by enabling models to learn more robust representations with greater generalization capability when dealing with the variability found in real-world scenarios.

However, neural network training using handwritten medical prescription data faces challenges related to data scarcity, image quality, and annotation quality. Data scarcity results from the limited availability of publicly available datasets for training, making it necessary to adopt data augmentation techniques to increase the number and diversity of training samples. Regarding image quality, this challenge is associated with the age of existing datasets, as older datasets often contain images with lower resolution, reduced sharpness, and a higher incidence of artifacts. These factors should be carefully considered during the data collection and preprocessing stages. Annotation quality also represents an important challenge, as each dataset may exhibit limitations associated with regional characteristics. Consequently, there is no guarantee that a dataset collected in the United States, for example, shares the same handwriting patterns, terminology, and structural characteristics as medical prescriptions written in Brazil or European countries. These differences reflect linguistic, cultural, and healthcare system variations across regions. To address these challenges, different strategies were adopted throughout this study to mitigate their impact and improve both the quality of model training and the generalization capability of the proposed neural networks.

Despite the limitations related to data availability, this study does not aim to collect new handwritten medical prescriptions or construct a novel dataset. Nevertheless, an adequate number of training samples is required to effectively train the neural network models. To address this limitation, data augmentation techniques are employed to increase data diversity

and improve the generalization capability of the models.

In this project, two datasets will be used to train the neural networks. Initially, each dataset will be used independently, allowing the performance of the models to be evaluated on each dataset separately. Subsequently, a new training process will be conducted using a combination of both datasets. This strategy aims to increase the number of available training samples while reducing the likelihood of overfitting.

The datasets selected for this study were RxHandBD [2] and PrescriptionBD [3], as they present characteristics that are well suited to the proposed task. Then, after applying data augmentation techniques and organizing the training sets, the data will be ready to be used for training the neural networks.

To conduct these experiments, four neural network architectures were evaluated: two based on Convolutional Neural Networks (CNNs) and two based on Transformers. The convolutional architectures selected were a CNN Baseline and a CNN-BiLSTM. They were chosen because they require lower computational cost and are less dependent on large volumes of training data, characteristics that are consistent with the data scarcity scenario addressed in this study.

The Transformer-based architectures selected were TrOCR and PARSeq. Both models were initialized from pre-trained weights and subsequently fine-tuned for the proposed task. This approach leverages knowledge acquired during pre-training, reducing the need for large task-specific datasets.

The performance evaluation was conducted by considering the characteristics of each architecture. Accordingly, the CNN-based models were analyzed within the training from scratch paradigm, whereas the Transformer-based models were evaluated under the fine-tuning paradigm. Thus, the comparisons were performed within the context of each training strategy, avoiding direct comparisons that could lead to misleading interpretations due to the inherent differences between their training processes.

A dedicated hardware platform was used throughout this study to support the continuous training and evaluation of the proposed models. The hardware specifications are presented in Table 1.

Table 1: Hardware configuration used in the experiments.

Component	**Specification**
CPU	Intel Xeon E5-2680 v4 (28 cores, 56 threads)
Motherboard	MOUGOL X99
RAM	8 GB DDR4
GPU	NVIDIA GeForce RTX 3050 Low Profile
Video Memory (VRAM)	6 GB

To evaluate the performance of the neural network architectures, multiple evaluation metrics were employed, with particular emphasis on the *Word Error Rate* (WER) and the *Character Error Rate* (CER). In addition to these metrics, the training and validation loss and accuracy were monitored throughout each training epoch, enabling the learning progression of the models to be analyzed.

The analysis of these metrics makes it possible not only to assess the models' ability to recognize words and characters but also to identify learning trends, including potential periods of stagnation or convergence. Consequently, it provides insights into how the characteristics of the datasets influence the performance of the different architectures, helping to identify the factors that improve or limit their recognition capabilities.

Within this context, the objective of this study is to evaluate, under a controlled experimental setting, four neural network architectures for handwritten medical prescription recognition. Furthermore, the study aims to investigate how the characteristics of the selected datasets

influence the performance of each architecture by analyzing the factors that contribute to improvements or reductions in recognition performance across different datasets.

2 Method

To ensure a fair comparison among all models, the same training configuration was adopted for every architecture. This approach enabled a consistent and unbiased benchmark across all evaluated models. To achieve this, a standardized training protocol was developed, in which all architectures were trained using the same settings, including the number of epochs, learning rate, and batch size. This protocol sought to minimize the influence of external factors on the training process, ensuring that the observed differences in performance were predominantly attributable to the characteristics of the evaluated architectures and datasets. Consequently, the comparison became more consistent, reliable, and representative of each model's actual performance.

At the end of the training process, the obtained results were consolidated through different evaluation procedures. To this end, tables containing the main performance metrics throughout the training process were generated, and the best-performing model across all training epochs was saved. Subsequently, this model was evaluated to obtain the final performance metrics, enabling a consistent assessment of its generalization capability. This approach provided a reliable basis for comparing the evaluated architectures.

2.1 Proposed Approach

The adopted methodology for comparing the models consisted of standardizing all experimental stages to ensure equivalent evaluation conditions. First, the dataset was preprocessed, including its organization and partitioning into training, validation, and test splits. Next, the models were implemented in Python and trained using the same hyperparameters, ensuring that performance differences were attributable to the evaluated architectures rather than training configurations. Finally, the models were evaluated using the test set, enabling a systematic comparison of the obtained results.

1. **Initializing the models:** Each architecture was configured with its respective parameters and output vocabulary. For transformer-based models, pre-trained checkpoints were used as the initial weights, whereas the remaining architectures were initialized with their default settings.

2. **Data processing:** The images were converted to grayscale, resized to a height of 64 pixels and a maximum width of 512 pixels, while preserving the aspect ratio and applying padding when necessary. Text labels were normalized by removing excess whitespace and converting all characters to lowercase. The data were organized into fixed training, validation, and test sets.

3. **Optimization:** Training was performed in batches using the AdamW optimizer. The loss function was defined according to the prediction strategy of each architecture, including cross-entropy loss, CTC loss, or a permutation-based loss. At the end of each epoch, performance on the validation set was monitored to select the best checkpoint.

4. **Evaluation:** The best checkpoint selected on the validation set was applied exclusively to the test set. Performance was quantified using exact-match accuracy, Character Error Rate (CER), and Word Error Rate (WER), allowing both complete prediction correctness and character- and word-level errors to be assessed.

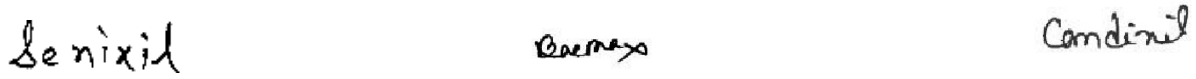
3 Experimental Setup

3.1 Datasets and Preprocessing

The *Doctor's Handwritten Prescription BD Dataset* (*PrescriptionBD*) was developed by researchers from Bangladesh to provide a public dataset for handwritten medical prescription recognition [4]. Its development was motivated by the limited availability of public datasets for training and evaluating handwriting recognition models in the medical domain. To construct the dataset, real medical prescriptions from Bangladesh were collected, and individual words were segmented and annotated. The dataset was then made publicly available, enabling its use in research on optical character recognition (OCR), handwritten text recognition (HTR), and artificial intelligence applications in healthcare.

The construction of *PrescriptionBD* involved segmenting, labeling, and classifying words extracted from medical prescriptions, resulting in an organized dataset suitable for training and evaluating handwriting recognition models. In general, the samples have good visual quality and sufficient sharpness to support feature extraction by deep learning architectures.

Figure 2 presents samples from *PrescriptionBD*. The dataset contains images with variable resolutions in both height and width, making it necessary to standardize them to a single size before training the neural networks. In addition, *PrescriptionBD* provides an official data split, which supports experiment reproducibility and consistent comparisons among different approaches.



(a) (b) (c)

Figure 2: Samples from PrescriptionBD

RxHandBD is a dataset developed by Md. Masudul Islam of the Bangladesh University of Business and Technology (BUBT) [2] and made publicly available through the Zenodo and Mendeley Data repositories. The dataset was created to provide a standardized benchmark for handwritten text recognition (HTR) and optical character recognition (OCR) research applied to handwritten medical prescriptions.

The RxHandBD documentation states that the samples were obtained from physical medical prescriptions, from which individual words were segmented and subsequently annotated. However, the available documentation does not provide detailed information about the prescription acquisition process, the number of professionals who participated in the collection, or the procedures used to digitize and segment the samples. The dataset contains 5,578 word images extracted from handwritten medical prescriptions, corresponding to 1,559 distinct words. Images are provided in JPG format, while their annotations are supplied in CSV files.

RxHandBD was selected for this study because it provides a standardized collection of words from handwritten medical prescriptions, including annotated transcriptions and an official division between training and test sets. Compared with *PrescriptionBD*, this dataset presents features such as thicker letter strokes and greater expression of regional variability in medical handwriting. These differences make *RxHandBD* relevant for evaluating model generalization under different handwriting patterns. From a comparative perspective, it is useful to investigate how the architectures perform on writing samples with distinct characteristics. These particularities can be observed in Figure 3, which shows representative examples of the handwriting characteristics found in the dataset.



(a) (b) (c)

Figure 3: Samples from RxHandBD

As previously discussed, *PrescriptionBD* contains images with non-standardized resolutions whose dimensions vary in both height and width. To ensure dataset uniformity and enable a direct comparison with *RxHandBD*, a resolution of 512×512 pixels was adopted as the input standard for all evaluated architectures. This standardization is also required to convert the images into fixed-size tensors, which is fundamental for training the neural networks.

White padding was used to preserve the prescription content and avoid distortions introduced by disproportionate resizing. In this procedure, each image was placed on a white background until it reached a resolution of 512×512 pixels, preserving its original proportions and adding padding pixels only to the remaining regions. As a result, all samples acquired uniform dimensions, making them suitable for processing by the deep learning architectures and enabling a fairer methodological comparison between the datasets. Figure 4 compares an image before and after standardization: Figure 4a shows the Lenixil prescription at 103×30 pixels, whereas Figure 4b shows it after standardization to 512×512 pixels.



(a) (b)

Figure 4: Example from *PrescriptionBD* after standardization to a resolution of 512×512 pixels.

Three distinct scenarios were considered in the experiments: training and evaluation exclusively on *PrescriptionBD*, training and evaluation exclusively on *RxHandBD*, and an additional combined scenario formed by joining the samples from both datasets. For the combined dataset, a new division into training and test sets was created according to the splits presented in Table 2. For *PrescriptionBD*, the official split provided by the authors was preserved to support experiment reproducibility and result comparability.

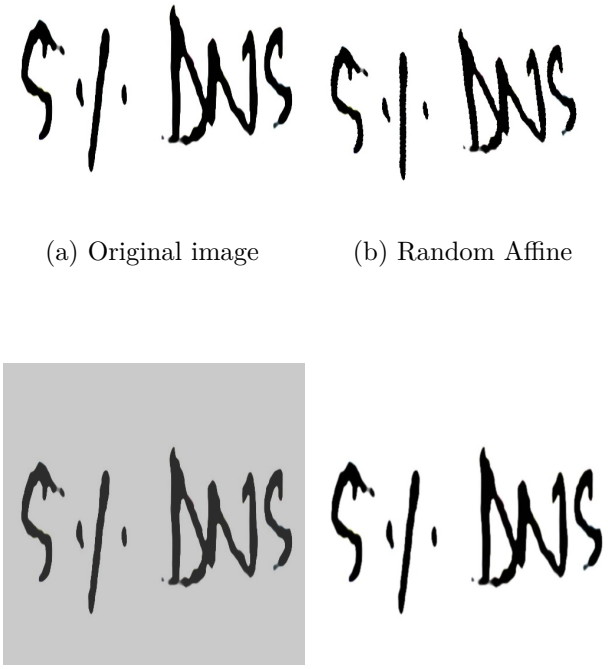
Table 2: Splits used in the different experimental scenarios.

Scenario	**Train**	**Val**	**Test**	**Total**	**Method**
RxHandBD	3905	837	836	5578	70/15/15 by sample, seed 757
PrescriptionBD	3120	780	780	4680	Official split preserved
Combined	7025	1617	1616	10258	Union of the corresponding splits

Because of the limited number of samples available for training, data augmentation was used to increase data variability and reduce the risk of model overfitting. The transformations were applied randomly during training, generating different variations of the same image in each epoch.

Three data augmentation techniques were used. The first was *RandomAffine*, which applies random rotations and translations to the images with a probability of 90%. The second was

ColorJitter, which randomly changes image brightness and contrast, with variations of 0.25 for brightness and 0.35 for contrast, and was applied with a probability of 60%. Finally, *GaussianBlur* was used with a kernel size of 3 and σ values ranging from 0.1 to 0.8, with an application probability of 30%. Figure 5 shows the result of applying this augmentation methodology to a sample from *RxHandBD*.



(a) Original image (b) Random Affine

(c) ColorJitter (d) Gaussian blur

Figure 5: Example of data augmentation transformations applied to a sample from the RxHandBD training set.

These transformations supported more consistent training with a lower occurrence of overfitting.

3.2 Computational Models

Four architectures were used in this study: a CNN baseline, a CNN-BiLSTM, TrOCR, and PARSeq.

3.2.1 CNN Baseline

Convolutional Neural Networks (CNNs) are inspired by principles observed in the biological visual system, particularly the studies of the visual cortex conducted by Hubel and Wiesel [5]. Although they do not faithfully reproduce how the human brain operates, these architectures were conceived from the observation that the visual system can recognize complex patterns through hierarchical combinations of simple visual features.

In the experiments conducted by Hubel and Wiesel, neurons in the visual cortex were found to respond selectively to specific stimuli such as edges, orientations, and contrasts. Visual information processing was also observed to occur hierarchically, with higher-level neurons integrating information extracted by simpler neurons to represent increasingly complex structures [5].

Inspired by these principles, CNNs introduce local receptive fields through convolutional layers, in which filters automatically learn patterns present in the images. As multiple convolutional layers are stacked, hierarchical feature representations can be constructed, beginning with basic elements such as edges and textures and progressing toward more complex patterns such as shapes and objects. This organization has made CNNs one of the main architectures used in computer vision and pattern recognition tasks.

The conceptual foundations of modern CNN models can be traced to Fukushima's work, presented in *Neocognitron: A Self-Organizing Neural Network Model for a Mechanism of Pattern Recognition Unaffected by Shift in Position* [6]. That study proposed a hierarchical architecture inspired by the visual cortex, with layers responsible for progressive feature extraction and invariance to small translations in the input patterns. Although the Neocognitron did not use *backpropagation* training, its architectural principles helped establish the foundation for modern CNNs.

LeCun et al. [7] later consolidated this paradigm by presenting a convolutional architecture trained with *backpropagation* for optical character recognition (OCR), demonstrating that automatically learned convolutional filters could achieve high performance in pattern recognition tasks. This work established a practical basis for the widespread adoption of CNNs in computer vision problems.

In this study, the CNN was used as a reference model (*baseline*), representing the starting point for comparison among the evaluated architectures. It establishes an initial performance level for traditional convolutional models in handwritten medical prescription recognition and provides a basis for analyzing the gains obtained with more sophisticated architectures.

However, the problem addressed in this work differs from a conventional image classification task. The objective is to recognize complete words in prescriptions, which characterizes a sequence recognition problem. A conventional CNN produces only one classification for each input image, preventing it from directly predicting all characters that form a word in a single inference.

To address this limitation, the CNN *baseline* was formulated as a word classifier. In this approach, each word in the training set is treated as a distinct class. The network output therefore corresponds to a probability distribution over all known classes, and the word with the highest probability is selected as the prediction. The model does not perform sequential character recognition; instead, it directly estimates which previously learned word corresponds to the input image.

As an extension of the CNN *baseline*, an architecture incorporating a *Bidirectional Long Short-Term Memory* (BiLSTM) layer was developed. This modification allows the model to move beyond the classification of previously known words and recognize the character sequence in the image, making it more suitable for handwritten text recognition tasks.

3.2.2 CNN BiLSTM

To improve recognition accuracy, a *Bidirectional Long Short-Term Memory* (BiLSTM) module was incorporated into the CNN baseline. This architecture is a recurrent neural network capable of modeling long-range sequential dependencies by processing a sequence in both the forward and backward directions [8]. The model can therefore consider not only the current element but also the context supplied by preceding and subsequent characters.

The inclusion of the BiLSTM is motivated by the inherent sequential structure of handwritten words. In a language, some characters are more likely to occur together, including common alternations between consonants and vowels and the spelling patterns associated with each word. By exploring these contextual dependencies, the BiLSTM complements the visual features extracted by the CNN, allowing the classification process to consider both character appearance and the sequential relationships among characters. The CNN-BiLSTM architecture was therefore evaluated for its ability to improve handwritten medical prescription recognition relative to the CNN baseline.

After incorporating the BiLSTM, the architecture produced temporal outputs and was trained with CTC over a character vocabulary. During greedy decoding, consecutive repetitions and the blank symbol are removed to reconstruct the predicted word. Unlike the CNN *baseline*, CNN-BiLSTM is therefore not restricted to a closed set of word classes and can form sequences that were not observed during training, provided that their characters belong to the learned vocabulary.

To broaden the comparison with sequence architectures initialized through large-scale pre-training, Transformer-based models were subsequently evaluated. These models also perform recognition at the character-sequence level and can recognize words that were not present in the training set.

3.2.3 TrOCR

TrOCR (Transformer-based Optical Character Recognition) is an optical character recognition model proposed by Li et al. [9] that uses an encoder-decoder architecture based entirely on Transformers. The model employs a visual Transformer to extract representations from the input image and a textual Transformer to generate the corresponding sequence of characters or tokens, eliminating the need for traditional CNN-, RNN-, and CTC-based architectures. TrOCR can also be pre-trained on large synthetic datasets and subsequently fine-tuned with labeled data, with applications to printed, handwritten, and scene text.

3.2.4 PARSeq

PARSeq (Permuted Autoregressive Sequence) is a Transformer-based model developed for text recognition in images, particularly in the context of Scene Text Recognition [10]. Unlike conventional autoregressive models, which generate characters only from left to right, PARSeq uses Permutation Language Modeling, allowing the model to learn different prediction orders and explore bidirectional context during recognition. This approach combines autoregressive inference, non-autoregressive inference, and iterative refinement within a single architecture, providing a balance among accuracy, parameter count, and computational cost.

3.3 Baselines and Metrics

An experiment matrix was initially defined to establish the training and test sets used for each model. This standardization enabled systematic evaluation with consistent metrics, making it possible to analyze the performance of each architecture and understand the factors that influenced the results. The results from all experiments were then compared.

To support a fair comparison among the architectures, specific comparison matrices were defined for each group of experiments. These matrices consider the conceptual differences among the models and their training particularities, avoiding inappropriate comparisons between distinct approaches. This procedure made it possible to evaluate the generalization capability and performance of each architecture under different scenarios and quantities of training data.

All experiments are presented in Table 3.

Table 3: Experiment matrix by architecture and dataset.

Exp.	Architecture	Dataset	Train	Validation	Test
E1	CNN baseline	PrescriptionBD	3120	780	780
E1	CNN baseline	RxHandBD	3905	837	836
E1	CNN baseline	Combined	7025	1617	1616
E2	CNN-BiLSTM	PrescriptionBD	3120	780	780
E2	CNN-BiLSTM	RxHandBD	3905	837	836
E2	CNN-BiLSTM	Combined	7025	1617	1616
E3	TrOCR	PrescriptionBD	3120	780	780
E3	TrOCR	RxHandBD	3905	837	836
E3	TrOCR	Combined	7025	1617	1616
E4	PARSeq	PrescriptionBD	3120	780	780
E4	PARSeq	RxHandBD	3905	837	836
E4	PARSeq	Combined	7025	1617	1616

Throughout training, performance metrics were collected at each epoch to characterize the progression of model learning. The loss values on the training and validation sets and the accuracy achieved on both sets were recorded.

The models were evaluated using metrics that capture different aspects of text recognition performance. Accuracy measured whether the model correctly recognized the complete character sequence in an image. Character Error Rate (CER) quantified character-level errors through the number of insertions, deletions, and substitutions required to transform the prediction into the reference text. Word Error Rate (WER) complemented this analysis by measuring word-level errors as the number of incorrectly recognized words relative to the expected text.

3.4 Implementation Details

The experiments were implemented in Python using the package developed for this project, named `med-ocr-research`. The execution environment uses Python 3.10 or later, with PyTorch as the main deep learning framework. All training runs were performed with CUDA acceleration on an NVIDIA GeForce RTX 3050 GPU with 6 GB of memory. The complete computational environment configuration is shown in Table 1.

The main dependencies used during development are presented in Table 4. The listed values represent the minimum versions used in the experimental environment. For TrOCR, the pre-trained model files record the use of Transformers version 5.12.1.

The random seed 42 was used throughout all experiments to support result reproducibility. This seed was applied to the generators from the `random`, NumPy, and PyTorch libraries, including CUDA initialization through `torch.cuda.manual_seed_all`. The official PrescriptionBD split was preserved when organizing the datasets. RxHandBD was divided into 70% for training, 15% for validation, and 15% for testing using the derived seed 757. The combined dataset was obtained by joining the corresponding subsets from the two datasets.

Table 4: Software dependencies used in the experimental environment.

Library	**Version**	**Library**	**Version**
Python	≥ 3.10	PyTorch	≥ 2.2
Torchvision	≥ 0.17	Transformers	5.12.1
NumPy	≥ 1.24	Pandas	≥ 2.0
Pillow	≥ 10.0	Timm	≥ 1.0
PyTorch Lightning	≥ 2.2	Accelerate	≥ 0.30
Albumentations	≥ 1.4	SentencePiece	$\geq 0.2.1$
NLTK	≥ 3.8	Tqdm	≥ 4.66
PyYAML	≥ 6.0	Protobuf	≥ 4.25

The CNN baseline and CNN-BiLSTM were implemented in this project. TrOCR used the pre-trained `microsoft/trocr-small-handwritten` checkpoint. PARSeq used the implementation available in the `baudm/parseq` repository, fixed at the following commit:

`1902db043c029a7e03a3818c616c06600af574be`

All developed source code, experimental configurations, and evaluation scripts are available in the project repository:

`https://github.com/SamuelFerrc/Medical-Handwriting-Ocr`

4 Results and Discussion

This section presents the results from twelve evaluations: four model families, each evaluated on PrescriptionBD, RxHandBD, and the combined scenario. The results are organized to support discussion at three levels: (i) aggregate comparison among models, (ii) dataset effects, and (iii) diagnostic analysis of each evaluation. The metrics were recalculated directly from the evaluated prediction files. Detailed tables remain available in the artifact folder for consultation but are not included in the main article in order to keep the results section concise.

4.1 Overall comparison

The aggregate comparison by model and scenario is presented in Figures 6, 7, and 8, which show exact-match accuracy, CER, and WER, respectively, for all twelve evaluations.

In addition to the graphs, Table 5 presents the aggregate metrics for each model and scenario in a compact format.

Table 5: Evaluation summary by model and scenario

Model	Scenario	N	Correct	Accuracy	CER	WER	Mean confidence
CNN	PrescriptionBD	780	322	0.4128	0.5328	0.5911	0.2728
CNN	RxHandBD	836	262	0.3134	0.5866	0.7313	0.2831
CNN	Combined	1616	463	0.2865	0.6467	0.7412	0.2458
CNN-BiLSTM	PrescriptionBD	780	527	0.6756	0.1868	0.3278	0.9822
CNN-BiLSTM	RxHandBD	836	436	0.5215	0.1811	0.4984	0.9767
CNN-BiLSTM	Combined	1616	927	0.5736	0.2064	0.4370	0.9823
TrOCR	PrescriptionBD	780	693	0.8885	0.0864	0.1127	0.9886
TrOCR	RxHandBD	836	612	0.7321	0.1122	0.2824	0.9745
TrOCR	Combined	1616	1307	0.8088	0.1024	0.2018	0.9826
PARSeq	PrescriptionBD	780	703	0.9013	0.0680	0.1000	0.9649
PARSeq	RxHandBD	836	579	0.6926	0.1067	0.3130	0.8880
PARSeq	Combined	1616	1270	0.7859	0.0943	0.2214	0.9344

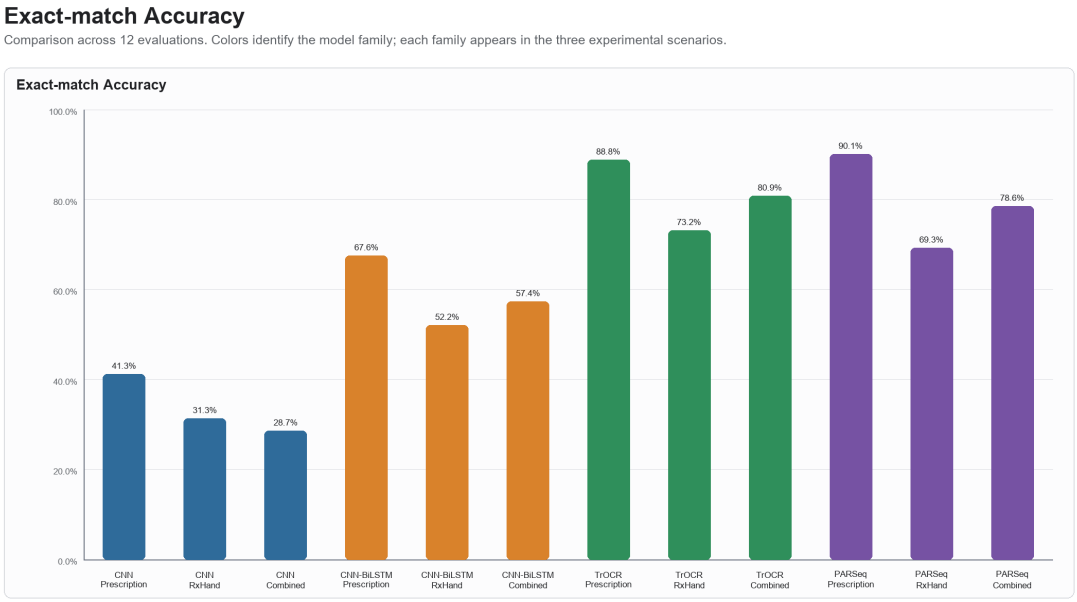


Figure 6: Exact-match accuracy across all twelve evaluations.

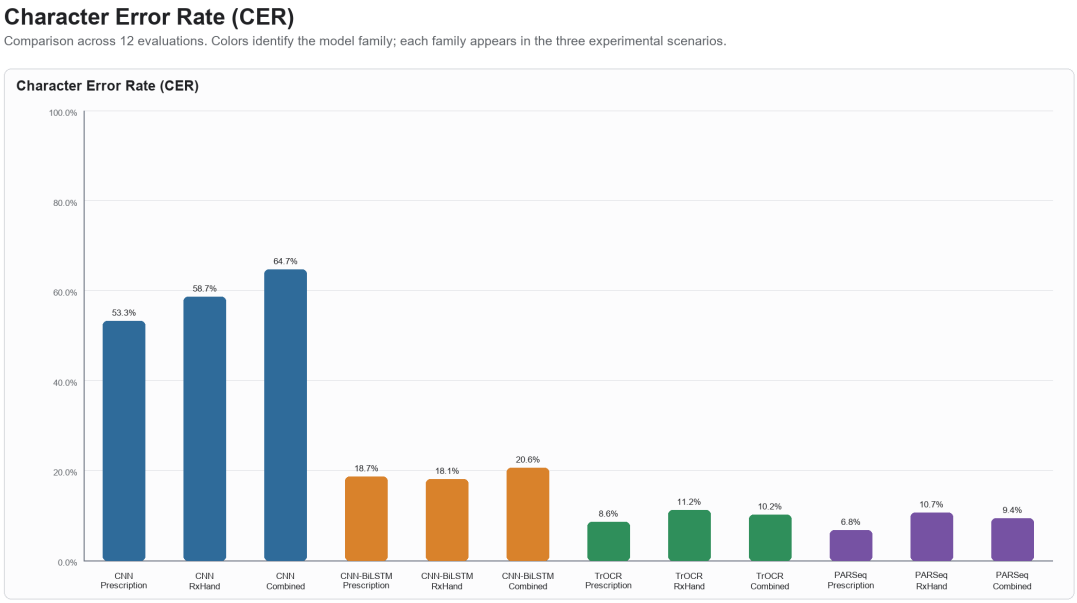


Figure 7: Character Error Rate (CER) across all twelve evaluations.

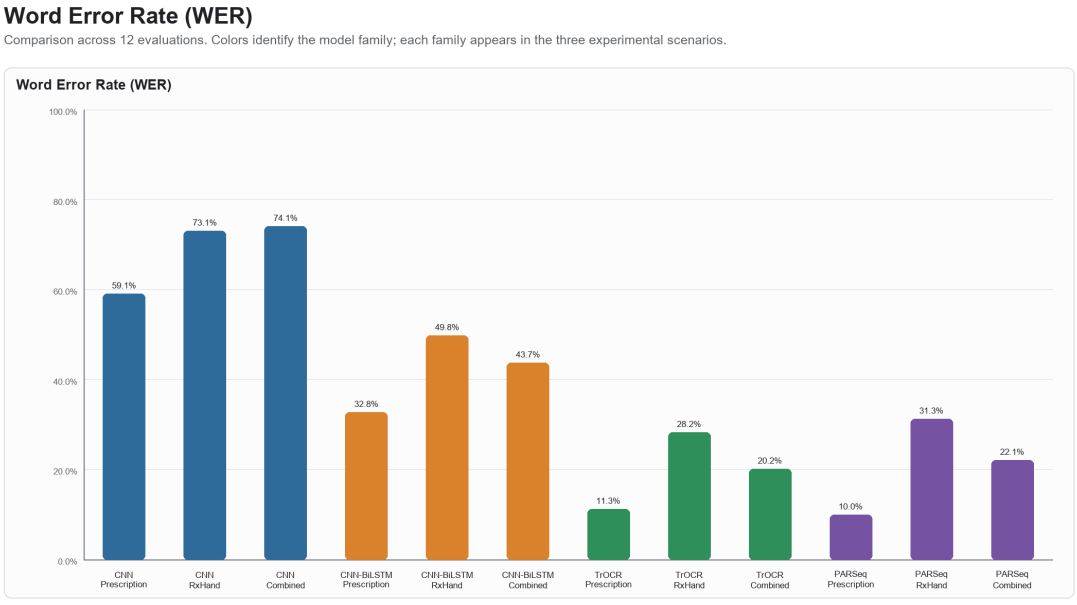


Figure 8: Word Error Rate (WER) across all twelve evaluations.

The results in Figure 6 show that all models achieved their best performance on PrescriptionBD. This pattern was not observed on RxHandBD, where most models performed worse, except for the CNN baseline, which produced relatively more consistent results.

This difference may be associated primarily with the visual characteristics of each dataset. As illustrated in Figure 3, RxHandBD images contain thicker, more blurred, and less clearly defined strokes, making it more difficult for both CNNs and Transformer-based models to extract discriminative features. In contrast, Figure 2 shows that PrescriptionBD contains characters with thinner, more continuous, and better-defined strokes, which may facilitate pattern identification and the learning of more robust representations by the neural networks. The observed visual-quality differences between the datasets are therefore consistent with the differences in model

performance during training and inference.

The experiments on the combined dataset produced intermediate performance relative to the two original datasets. This behavior was expected because the combined set includes both the favorable characteristics of PrescriptionBD and the challenges present in RxHandBD. The models were exposed to higher-quality examples as well as samples with greater visual complexity, resulting in average performance between the two original scenarios.

One notable result was that CNN-BiLSTM achieved a lower CER on RxHandBD than on PrescriptionBD, as shown in Figure 7. This result indicates that, although RxHandBD was more challenging for most of the evaluated models, CNN-BiLSTM recognized individual characters more accurately in this specific scenario.

Across all evaluated models and datasets, WER behaved consistently with overall accuracy, as illustrated in Figure 8. In general, models with higher accuracy also had lower WER values, showing the inverse relationship between these metrics and supporting the consistency of the experimental results.

4.2 Dataset-specific comparison

To separate the effect of the combined scenario from the effect of the architecture, Figure 9 presents the comparison of accuracy, CER, and WER by dataset.

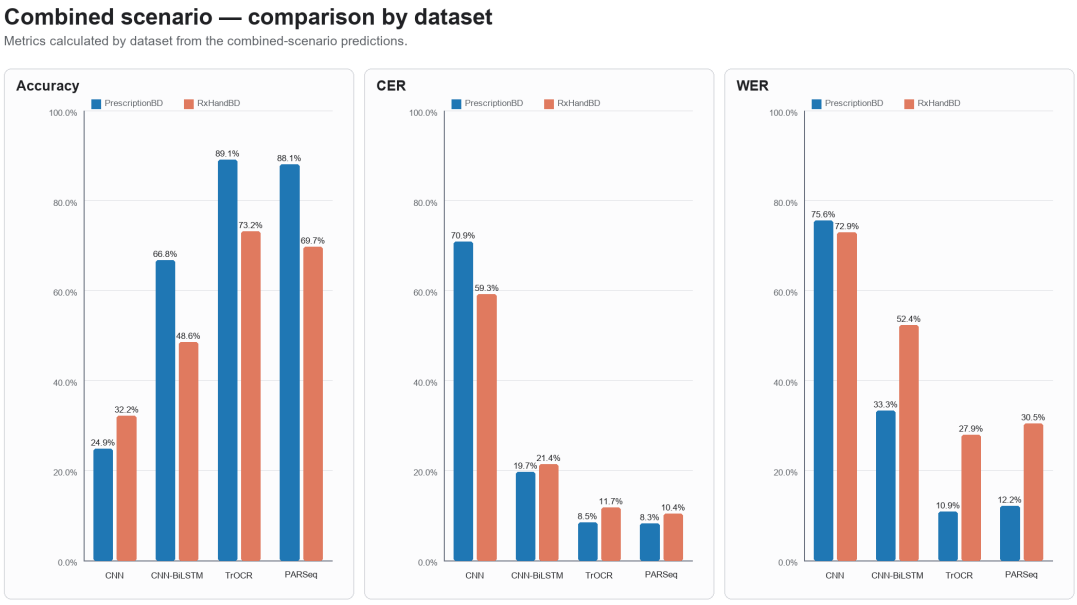


Figure 9: Comparison of the combined scenario by dataset.

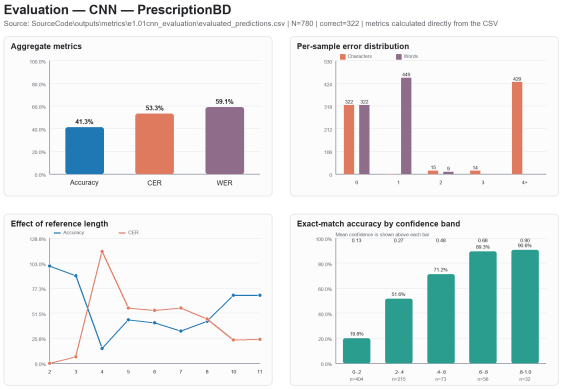
For each neural network model, the difference between the results represented by the blue and orange bars was calculated for overall accuracy. The CNN baseline was the only model for which the orange bar exceeded the blue bar, with a difference of 7.3 percentage points. For the remaining models, the blue bar showed better performance, with differences of 18.2 percentage points for CNN-BiLSTM, 15.9 percentage points for TrOCR, and 18.4 percentage points for PARSeq.

4.3 Per-evaluation diagnostic views

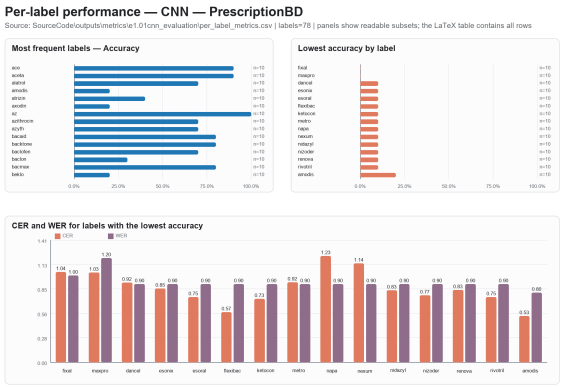
The figures in this subsection complement the aggregate metrics. Each evaluated prediction panel includes the error distribution, the relationship between performance and reference length, and accuracy by confidence range. The per-label panel shows the distribution of performance

across words, highlighting the most frequent labels and those with the lowest accuracy. These panels are descriptive and should be used to investigate error patterns rather than as substitutes for the aggregate metrics.

4.3.1 CNN baseline

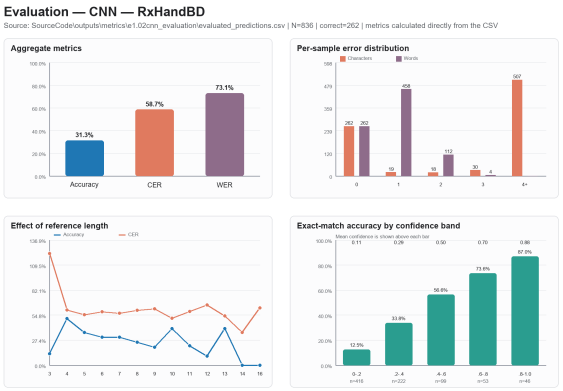


(a) Evaluated predictions.

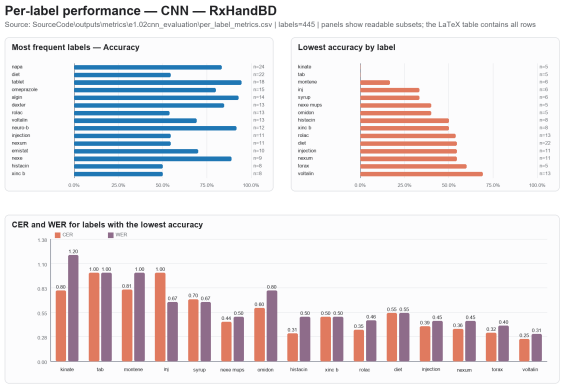


(b) Per-label metrics.

Figure 10: CNN baseline evaluated on PrescriptionBD.

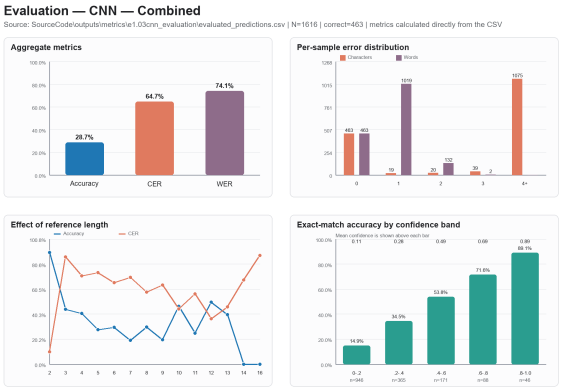


(a) Evaluated predictions.

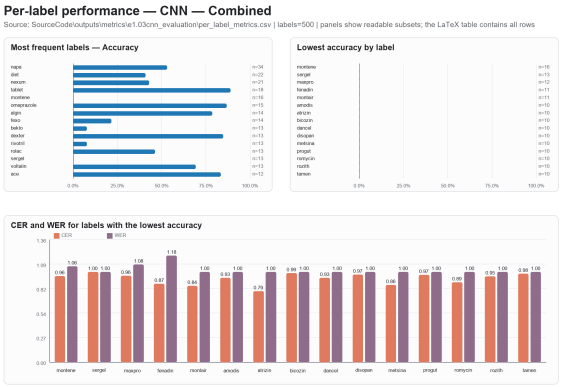


(b) Per-label metrics.

Figure 11: CNN baseline evaluated on RxHandBD.



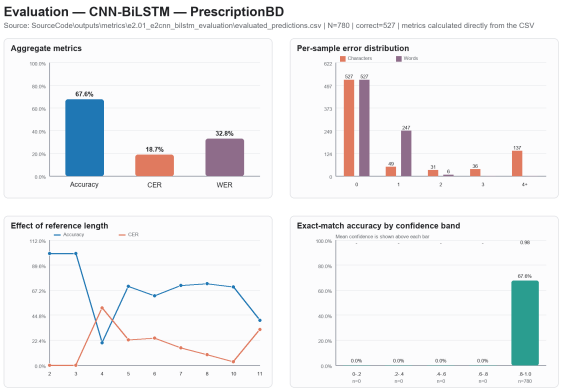
(a) Evaluated predictions.



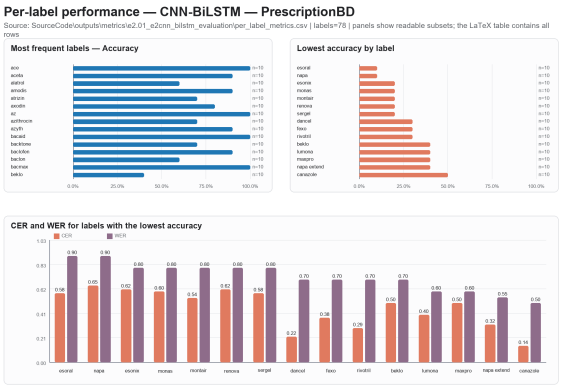
(b) Per-label metrics.

Figure 12: CNN baseline evaluated in the combined scenario.

4.3.2 CNN-BiLSTM

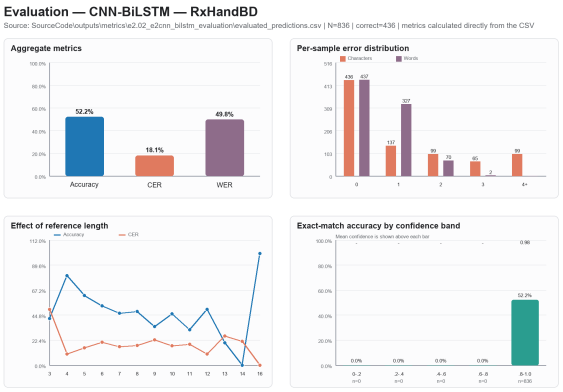


(a) Evaluated predictions.

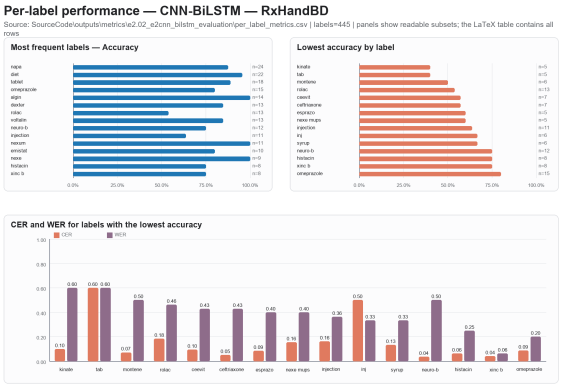


(b) Per-label metrics.

Figure 13: CNN-BiLSTM evaluated on PrescriptionBD.

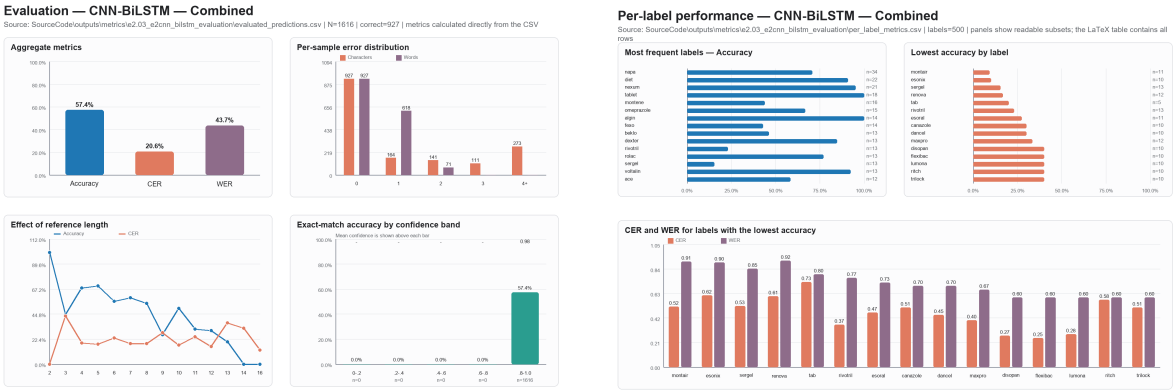


(a) Evaluated predictions.



(b) Per-label metrics.

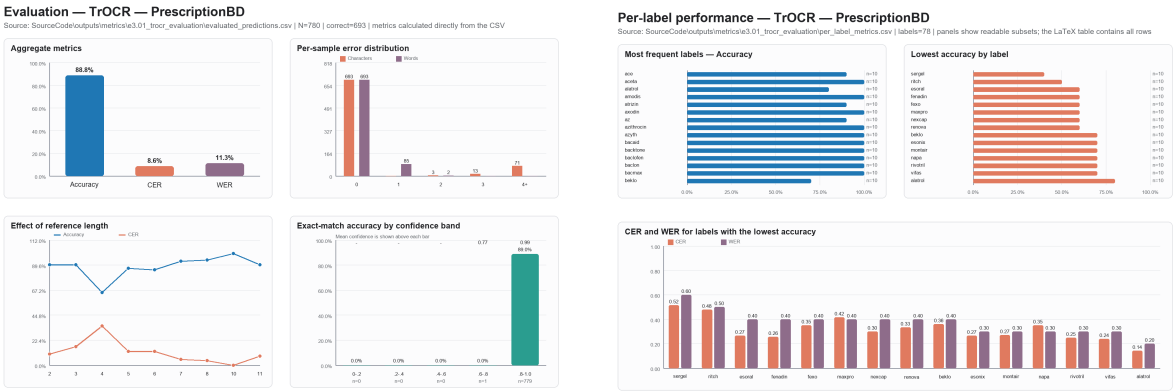
Figure 14: CNN-BiLSTM evaluated on RxHandBD.



(a) Evaluated predictions. (b) Per-label metrics.

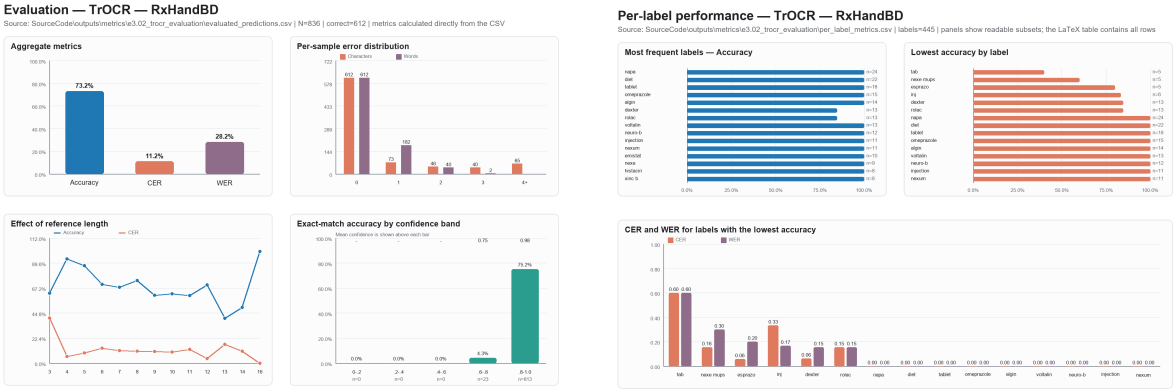
Figure 15: CNN-BiLSTM evaluated in the combined scenario.

4.3.3 TrOCR



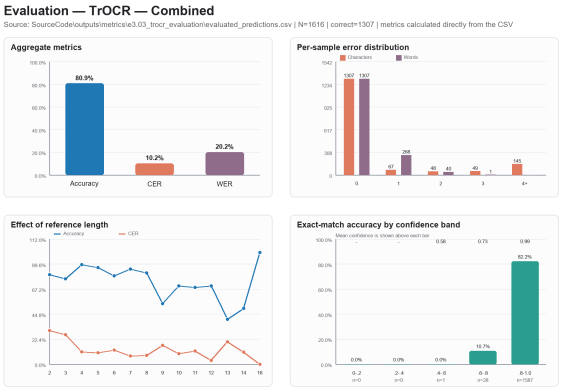
(a) Evaluated predictions. (b) Per-label metrics.

Figure 16: TrOCR evaluated on PrescriptionBD.

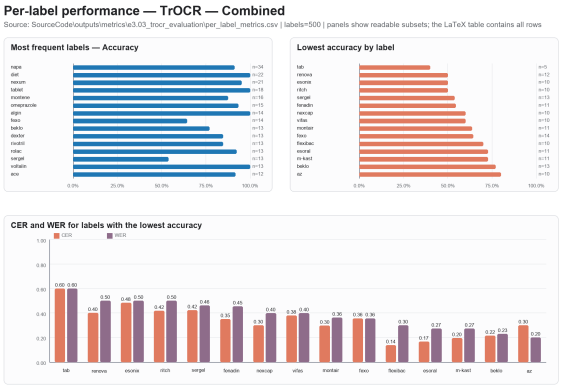


(a) Evaluated predictions. (b) Per-label metrics.

Figure 17: TrOCR evaluated on RxHandBD.



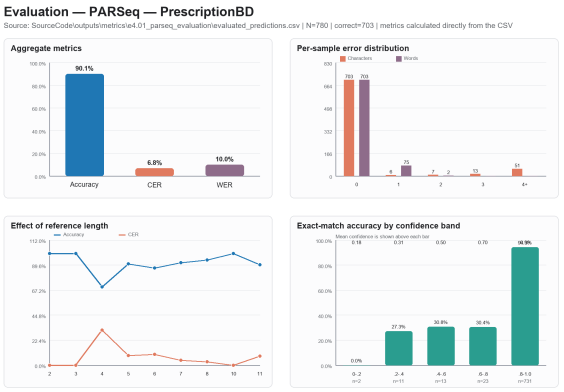
(a) Evaluated predictions.



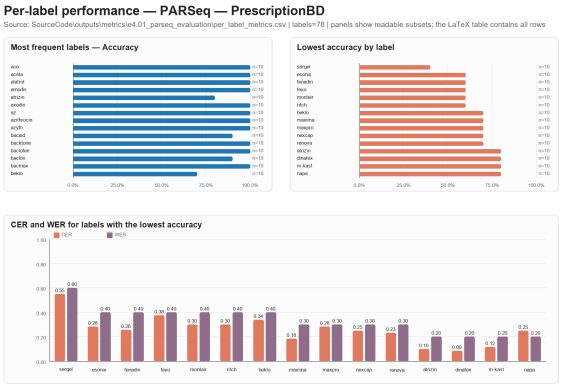
(b) Per-label metrics.

Figure 18: TrOCR evaluated in the combined scenario.

4.3.4 PARSeq

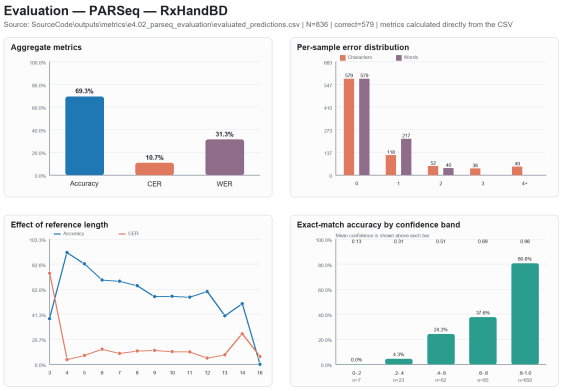


(a) Evaluated predictions.

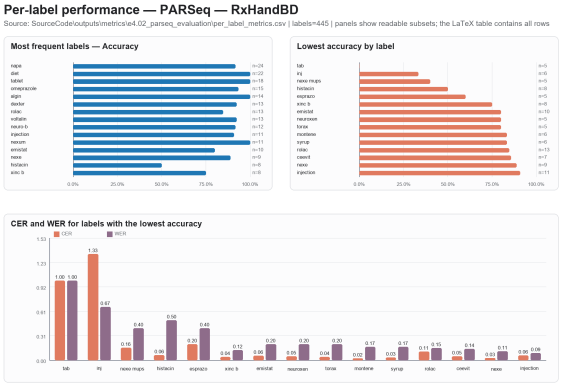


(b) Per-label metrics.

Figure 19: PARSeq evaluated on PrescriptionBD.

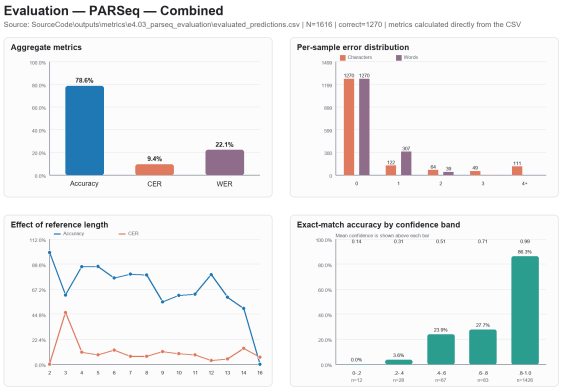


(a) Evaluated predictions.

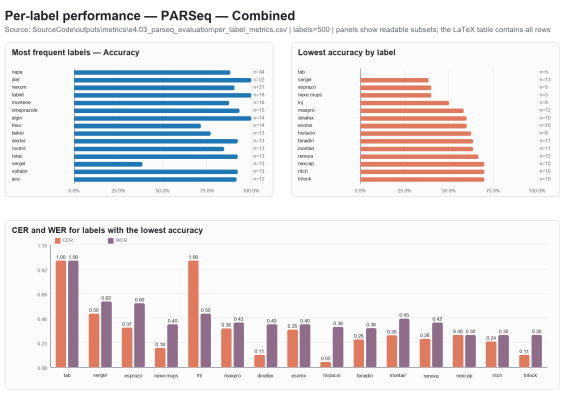


(b) Per-label metrics.

Figure 20: PARSeq evaluated on RxHandBD.



(a) Evaluated predictions.



(b) Per-label metrics.

Figure 21: PARSeq evaluated in the combined scenario.

5 Limitations

This study has limitations related to the amount of available data and the training batch sizes, which were restricted by the available memory capacity. These limitations may have introduced some bias into the results. However, all models were trained and evaluated under the same experimental conditions, using the same computational environment and training configurations, to provide the fairest possible comparison among the methods.

6 Conclusion

The results demonstrate the potential of sequence-recognition models for transcribing handwritten words in medical prescriptions. In particular, TrOCR and PARSeq achieved the best performance among the evaluated methods, with consistent advantages over the CNN baseline in all three experimental scenarios. PARSeq performed best on PrescriptionBD, reaching 90.13% accuracy, a CER of 0.0680, and a WER of 0.1000, whereas TrOCR achieved the best overall performance in the combined scenario in terms of accuracy (80.88%) and WER (0.2018). These results indicate that pre-trained models adapted through *fine-tuning* are an effective strategy for OCR of handwritten medical text, even under limited-data conditions.

Code and Data Availability

The code, data, and supplementary materials are available at:

`https://github.com/SamuelFerrc/Medical-Handwriting-Ocr`

References

[1] Usman Ali, Sahil Ranmbail, Muhammad Nadeem, Hamid Ishfaq, Muhammad Umer Ramzan, and Waqas Ali. Leveraging deep learning with multi-head attention for accurate extraction of medicine from handwritten prescriptions, 2024. URL `https://doi.org/10.48550/arXiv.2412.18199`.

[2] Md Masudul Islam. RxHandBD: A handwritten prescription word image dataset. Mendeley Data, 2026. Version 3.

[3] Abdur Rahim Mia, Abdullah Al Mamun, Abdullah Al Sajid, and Aurunave Mollik Ruddra. Doctor's handwritten prescription BD dataset. Kaggle, 2024. URL `https://www.kaggle.com/dsv/8378585`.

[4] A. R. Mia, M. A.-A.-S. Chowdhury, A. A. Mamun, A. M. Ruddra, and N. T. Tanny. A deep neural network approach with pioneering local dataset to recognize doctor's handwritten prescription in bangladesh. In *2024 International Conference on Advances in Computing, Communication, Electrical, and Smart Systems (iCACCESS)*, Dhaka, Bangladesh, 2024.

[5] David H. Hubel and Torsten N. Wiesel. Receptive fields, binocular interaction and functional architecture in the cat's visual cortex. 1962.

[6] Kunihiko Fukushima. Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position. *Biological Cybernetics*, 36(4):193–202, 1980. doi: 10.1007/BF00344251.

[7] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998. doi: 10.1109/5.726791.

[8] Baoguang Shi, Xiang Bai, and Cong Yao. An end-to-end trainable neural network for image-based sequence recognition and its application to scene text recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 2564–2572, 2016. doi: 10.1109/CVPR.2016.277.

[9] Minghao Li, Tengchao Lv, Jingye Chen, Lei Cui, Yijuan Lu, Dinei Florencio, Cha Zhang, Zhoujun Li, and Furu Wei. TrOCR: Transformer-based optical character recognition with pre-trained models. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pages 13094–13102, 2023. doi: 10.1609/aaai.v37i11.26538.

[10] Darwin Bautista and Rowel Atienza. Scene text recognition with permuted autoregressive sequence models. *arXiv preprint arXiv:2207.06966*, 2022.

Avaliação Comparativa de Métodos Neurais de OCR para o Reconhecimento de Palavras Manuscritas em Imagens de Prescrições Médicas

Samuel F. Santos*
Universidade Estadual de Santa Cruz

Resumo

Este estudo apresenta uma comparação prática entre modelos baseados em CNN e Transformers para o reconhecimento de palavras manuscritas em imagens de prescrições médicas. Foram avaliados dois conjuntos de dados de origem, o RxHandBD e o Doctor's Handwritten PrescriptionBD, individualmente e em um cenário de treinamento combinado. O treinamento do zero foi utilizado para uma CNN baseline, formulada como um classificador de palavras em vocabulário fechado, e para um modelo CNN-BiLSTM de reconhecimento sequencial. Já os Transformers pré-treinados TrOCR e PARSeq foram submetidos a fine-tuning para a transcrição de sequências de caracteres. O estudo analisa como as características dos conjuntos de dados, os regimes de treinamento e as diferentes formulações da tarefa afetam o desempenho do reconhecimento, as limitações dos modelos e o custo de treinamento em condições de disponibilidade limitada de dados.

This study presents a practical comparison of CNN-based and Transformer-based models for handwritten word recognition in medical prescription images. Two source datasets, RxHandBD and Doctor's Handwritten PrescriptionBD, were evaluated individually and in a combined training scenario. From-scratch training was used for a CNN baseline formulated as a closed-set word classifier and for a CNN-BiLSTM sequence-recognition model, whereas the pre-trained TrOCR and PARSeq Transformers were fine-tuned for character-sequence transcription. The study examines how dataset characteristics, training regimes, and task formulations affect recognition performance, model limitations, and training cost under limited-data conditions.

Keywords: Neural Network; Convulation; Transformers; Artificial Intelligence.

1 Introduction

Durante atendimentos médicos, é comum que seja emitida uma prescrição médica contendo informações sobre medicamentos e orientações relacionadas ao tratamento do paciente, com o objetivo de auxiliar na recuperação e na melhoria de seu quadro clínico. Entretanto, o conteúdo dessas prescrições é fortemente influenciado pela caligrafia e pelo contexto em que são elaboradas. Em muitos casos, fatores como a urgência do atendimento e a elevada demanda de pacientes nos ambientes hospitalares impactam diretamente a qualidade da escrita do profissional de saúde.

Como consequência, as prescrições médicas frequentemente apresentam baixo grau de legibilidade, tornando sua interpretação um desafio tanto para farmacêuticos quanto para os próprios pacientes. Essa dificuldade de compreensão levou diversos países e instituições de saúde a adotarem prescrições exclusivamente em formato digital como forma de minimizar erros de interpretação. No entanto, essa abordagem não representa a realidade de todos os contextos, nos quais prescrições manuscritas ainda permanecem amplamente utilizadas. Dessa forma, torna-se

*E-mail: sfsantos.cic@uesc.br

relevante investigar e compreender a dificuldade inerente aos caracteres e símbolos de prescrições médicas manuscritas, bem como avaliar a possibilidade de generalizar esse entendimento para outros tipos de escrita manual.

Tem-se que, manuscritos tendem a apresentar características relevantes para este estudo, representadas por formas geométricas simplificadas e por estruturas que podem ser compreendidas a partir dos símbolos que compõem a escrita. Dessa forma, as Figuras 1a e 1b evidenciam essas formas básicas, nas quais também são observados ruídos e irregularidades decorrentes das adversidades do ambiente de escrita previamente mencionadas. Assim, essas imagens podem ser utilizadas para a compreensão de padrões geométricos bidimensionais mais complexos, fornecendo uma representação adequada das características estruturais presentes na caligrafia.



(a) (b)

Figura 1: Caracteristicas Geometricas em Prescrições Medicas

No contexto de redes neurais, torna-se relevante avaliar a capacidade de diferentes arquiteturas em compreender e classificar estruturas caligráficas. Esse interesse se justifica tanto pela possibilidade de classificação automática de prescrições médicas quanto pelo potencial de utilização dessas estruturas como base para o aprendizado de representações aplicáveis a problemas envolvendo padrões geométricos de maior complexidade, conforme demonstrado em [1]. As características geométricas presentes em anotações manuscritas são particularmente relevantes para o treinamento de modelos, pois refletem a naturalidade e a organicidade do contexto em que são produzidas. Além disso, incorporam variações decorrentes da dinâmica da escrita, da individualidade do autor e de influências externas, diferenciando-se de dados sintéticos, que geralmente apresentam padrões mais controlados e menor variabilidade. Dessa forma, o emprego dessas estruturas no treinamento de redes neurais mostra-se útil para o aprendizado de representações mais robustas e com maior capacidade de generalização frente à variabilidade encontrada em cenários reais.

No entanto, o treinamento de redes neurais com dados provenientes de prescrições médicas enfrenta barreiras relacionadas à escassez de dados, à qualidade das imagens e à rotulação. A escassez de dados decorre da limitada disponibilidade de conjuntos de dados públicos para treinamento, tornando necessária a adoção de técnicas de aumento de dados (*data augmentation*) para ampliar a quantidade de amostras disponíveis. Em relação à qualidade das imagens, esse desafio está associado à idade dos datasets existentes, uma vez que conjuntos de dados mais antigos tendem a apresentar imagens com menor resolução, menor nitidez e maior incidência de artefatos, fatores que devem ser considerados durante o processo de coleta e preparação dos dados. Quanto à rotulação, cada dataset pode apresentar limitações decorrentes de aspectos regionais, não havendo garantia de que um conjunto de dados proveniente dos Estados Unidos, por exemplo, possua as mesmas características caligráficas, terminológicas e estruturais das

prescrições médicas brasileiras ou de países europeus. Essas diferenças refletem particularidades linguísticas, culturais e dos próprios sistemas de saúde adotados em cada país. Diante desses desafios, diferentes abordagens foram empregadas ao longo desta pesquisa com o objetivo de minimizar seus impactos e reduzir possíveis prejuízos à qualidade do treinamento e à capacidade de generalização das redes neurais.

Apesar das limitações relacionadas à disponibilidade de dados, este estudo não tem como objetivo realizar uma nova coleta para a construção de um dataset inédito de prescrições médicas. Entretanto, é necessário utilizar uma quantidade adequada de amostras para o treinamento das redes neurais. Para isso, serão aplicadas técnicas de *data augmentation*, com o objetivo de ampliar a diversidade dos dados e aumentar a capacidade de generalização dos modelos.

Serão utilizados dois datasets para o treinamento das redes neurais. Inicialmente, cada dataset será empregado de forma independente, permitindo a avaliação do desempenho dos modelos em cada conjunto de dados. Posteriormente, será realizado um novo treinamento utilizando a combinação dos dois datasets. Essa estratégia busca ampliar a quantidade de amostras disponíveis para treinamento, ao mesmo tempo em que procura reduzir a possibilidade de ocorrência de *overfitting*.

Os datasets selecionados para este estudo foram o RxHandBD [2] e o PrescriptionBD [3], por apresentarem características adequadas para a tarefa proposta. Após a aplicação das técnicas de aumento de dados e da organização dos conjuntos de treinamento, os dados estarão devidamente preparados para o treinamento das redes neurais.

Para a realização dos experimentos, foram avaliadas quatro arquiteturas de redes neurais, sendo duas baseadas em Redes Neurais Convolucionais (CNNs) e duas baseadas em Transformers. As arquiteturas convolucionais selecionadas foram uma CNN Baseline e uma CNN-BiLSTM, escolhidas por apresentarem menor custo computacional e menor dependência de grandes volumes de dados para treinamento, características compatíveis com o cenário de escassez de dados abordado neste estudo.

As arquiteturas baseadas em Transformers foram o TrOCR e o PARSeq, ambos utilizados a partir de modelos pré-treinados e posteriormente adaptados à tarefa por meio da técnica de *fine-tuning*. Essa abordagem permite aproveitar o conhecimento previamente adquirido durante o pré-treinamento, reduzindo a necessidade de grandes conjuntos de dados específicos para a tarefa.

A avaliação de desempenho foi conduzida considerando as particularidades de cada arquitetura. Dessa forma, as CNNs foram analisadas dentro do contexto de treinamento do zero (*training from scratch*), enquanto os modelos baseados em Transformers foram avaliados no contexto de *fine-tuning*. Assim, as comparações foram realizadas respeitando o cenário de utilização de cada abordagem, evitando comparações diretas que poderiam resultar em interpretações inadequadas devido às diferenças entre seus processos de treinamento.

E para este estudo foi utilizado o hardware da Tabela 1.

Tabela 1: Configuração de hardware utilizada nos experimentos.

Componente	**Especificação**
Processador (CPU)	Intel Xeon E5-2680 v4 (28 núcleos, 56 threads)
Placa-mãe	MOUGOL X99
Memória RAM	8 GB DDR4
Placa de Vídeo (GPU)	NVIDIA GeForce RTX 3050 Low Profile
Memória de Vídeo (VRAM)	6 GB

Para a avaliação do desempenho das arquiteturas de redes neurais, foram empregadas diferentes métricas de desempenho, destacando-se a *Word Error Rate* (WER) e a *Character Error Rate* (CER). Além dessas métricas, também foram analisados, ao longo de cada época de

treinamento, os valores de perda (*loss*) e de acurácia, permitindo acompanhar a evolução do aprendizado dos modelos.

A análise dessas métricas possibilita avaliar não apenas a capacidade de reconhecimento de palavras e caracteres, mas também identificar a evolução do treinamento, bem como possíveis períodos de estagnação ou convergência. Dessa forma, torna-se possível compreender como as características dos datasets influenciam o desempenho das arquiteturas, contribuindo para a identificação de fatores que favorecem ou limitam a obtenção de melhores resultados.

Diante desse contexto, o objetivo deste estudo é, em um ambiente controlado, avaliar 4 arquiteturas de redes neurais aplicadas ao reconhecimento de prescrições médicas manuscritas. Além disso, busca-se identificar as características dos datasets que influenciam o desempenho de cada arquitetura, analisando quais fatores contribuem para o aumento ou a redução da capacidade de reconhecimento em cada conjunto de dados.

2 Method

Para garantir que a comparação entre as arquiteturas fosse conduzida de maneira justa e controlada, este *benchmark* foi estruturado de modo a maximizar a igualdade das condições experimentais entre os dois *datasets*. Com esse objetivo, foi desenvolvido um protocolo de treinamento padronizado, no qual todas as arquiteturas foram submetidas às mesmas configurações de treinamento, incluindo o número de épocas, a taxa de aprendizado (*learning rate*) e o tamanho dos *batches*. Dessa forma, buscou-se minimizar a influência de fatores externos ao processo de treinamento, permitindo que as diferenças observadas nos resultados estivessem predominantemente associadas às características das arquiteturas e dos *datasets* avaliados, tornando a comparação mais consistente e confiável.

Ao término do processo de treinamento, buscou-se consolidar os resultados obtidos por meio de diferentes formas de avaliação. Para isso, foram geradas tabelas contendo as principais métricas de desempenho ao longo do treinamento, além do armazenamento do modelo com melhor desempenho entre todas as épocas. Posteriormente, esse modelo foi submetido à etapa de avaliação, permitindo a obtenção de métricas finais e uma análise consistente de sua capacidade de generalização, fornecendo uma base confiável para a comparação entre as arquiteturas.

2.1 Proposed Approach

A abordagem adotada para a comparação dos modelos consistiu na padronização de todas as etapas experimentais, de modo a garantir condições equivalentes de avaliação. Inicialmente, foi realizado o pré-processamento dos dados, incluindo sua organização e divisão em *splits* de treinamento, validação e teste. Em seguida, os modelos foram desenvolvidos computacionalmente na linguagem Python e treinados utilizando os mesmos hiperparâmetros, assegurando que diferenças de desempenho estivessem relacionadas às arquiteturas avaliadas, e não às configurações de treinamento. Por fim, os modelos foram submetidos ao processo de avaliação, permitindo a comparação sistemática dos resultados obtidos.

1. **Inicialização do modelo:** cada arquitetura foi configurada com seus respectivos parâmetros e vocabulário de saída. Para os modelos baseados em transformadores, foram utilizados *checkpoints* pré-treinados como ponto de partida, enquanto as demais arquiteturas foram instanciadas conforme suas definições implementadas.

2. **Processamento dos dados:** as imagens foram convertidas para escala de cinza, redimensionadas para altura de 64 pixels, com largura máxima de 512 pixels, preservando-se a razão de aspecto e aplicando-se preenchimento quando necessário. Os rótulos textuais foram normalizados por meio da remoção de espaços excedentes e conversão para letras

minúsculas. Os dados foram organizados em conjuntos fixos de treinamento, validação e teste.

3. **Otimização:** o treinamento foi realizado em *batches*, utilizando o otimizador AdamW. A função de perda foi definida de acordo com a estratégia de predição de cada arquitetura, incluindo perda por entropia cruzada, CTC ou perda baseada em permutações. Ao final de cada época, o desempenho no conjunto de validação foi monitorado para selecionar o melhor *checkpoint*.

4. **Avaliação:** o melhor *checkpoint* selecionado na validação foi aplicado exclusivamente ao conjunto de teste. O desempenho foi quantificado por acurácia de correspondência exata, *Character Error Rate* (CER) e *Word Error Rate* (WER), permitindo avaliar tanto a correção integral das predições quanto os erros em nível de caracteres e palavras.

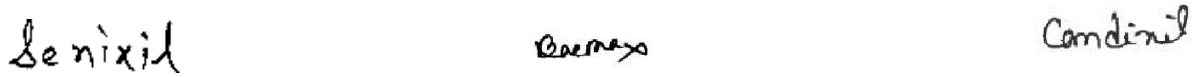
3 Experimental Setup

3.1 Datasets and Preprocessing

O *Doctor's Handwritten Prescription BD Dataset* (*PrescriptionBD*) foi desenvolvido por pesquisadores de Bangladesh com o propósito de disponibilizar um conjunto de dados público voltado ao reconhecimento de prescrições médicas manuscritas [4]. O desenvolvimento do dataset foi motivado pela limitada disponibilidade de bases públicas para o treinamento e a avaliação de modelos de reconhecimento de escrita manuscrita aplicados ao contexto médico. Para sua construção, foram coletadas prescrições médicas reais provenientes de Bangladesh, das quais palavras individuais foram segmentadas e posteriormente anotadas para compor o conjunto de dados. Ao final do processo, o dataset foi disponibilizado publicamente, possibilitando sua utilização em pesquisas relacionadas ao reconhecimento óptico de caracteres (OCR), ao reconhecimento de texto manuscrito (HTR) e a aplicações de inteligência artificial na área da saúde.

A construção do *PrescriptionBD* envolveu procedimentos de segmentação, rotulação e classificação das palavras extraídas das prescrições médicas, resultando em um conjunto de dados organizado e apropriado para o treinamento e a avaliação de modelos de reconhecimento de escrita manuscrita. As amostras apresentam, em geral, boa qualidade visual, com níveis de nitidez que favorecem a extração de características pelas arquiteturas de aprendizado profundo.

Na Figura 2 são apresentadas algumas amostras do *PrescriptionBD*. Observa-se que o dataset possui imagens com resoluções variáveis, tanto em altura quanto em largura, tornando necessária a realização de uma etapa de padronização para um tamanho único antes do treinamento das redes neurais. Além disso, o *PrescriptionBD* já disponibiliza uma divisão oficial dos dados em conjuntos de treinamento e teste (*train/test split*), característica que contribui para a reprodutibilidade dos experimentos e permite a comparação consistente entre diferentes abordagens.



(a) (b) (c)

Figura 2: Amostras do PrescriptionBD

O RxHandBD é um conjunto de dados desenvolvido por Md. Masudul Islam, da Bangladesh University of Business and Technology (BUBT) [2], e disponibilizado publicamente por meio dos repositórios Zenodo e Mendeley Data. O dataset foi criado com o objetivo de fornecer um benchmark padronizado para pesquisas em reconhecimento de escrita manuscrita (HTR) e reconhecimento óptico de caracteres (OCR) aplicados a prescrições médicas manuscritas.

A documentação do *RxHandBD* informa que as amostras foram obtidas a partir de prescrições médicas físicas, das quais palavras individuais foram segmentadas e posteriormente anotadas. No entanto, a documentação disponibilizada não fornece informações detalhadas sobre o processo de aquisição das prescrições, o número de profissionais participantes da coleta, nem os procedimentos empregados para digitalização e segmentação das amostras. O dataset é composto por 5.578 imagens de palavras extraídas de prescrições médicas manuscritas, correspondentes a 1.559 palavras distintas. As imagens são disponibilizadas no formato JPG, enquanto suas respectivas anotações são fornecidas em arquivos CSV.

O *RxHandBD* foi selecionado neste estudo por disponibilizar um conjunto padronizado de palavras provenientes de prescrições médicas manuscritas, contendo transcrições anotadas e uma divisão oficial entre os conjuntos de treinamento e teste. Em comparação ao *PrescriptionBD*, esse dataset apresenta características como maior espessura dos traços das letras e maior expressão da variabilidade regional das caligrafias presentes em prescrições médicas. Essas diferenças tornam o *RxHandBD* um recurso relevante para avaliar a capacidade de generalização dos modelos em cenários com diferentes padrões de escrita manuscrita. Sob uma perspectiva comparativa, é de interesse investigar o desempenho das arquiteturas diante de materiais de escrita com características distintas. Essas particularidades podem ser observadas na Figura 3, que ilustra exemplos representativos das características caligráficas presentes no dataset.



(a) (b) (c)

Figura 3: Amostras do RxHandBD

Conforme discutido anteriormente, o *PrescriptionBD* apresenta imagens com resoluções não padronizadas, cujas dimensões variam tanto em altura quanto em largura. Para garantir a uniformidade do conjunto de dados e possibilitar uma comparação direta com o *RxHandBD*, adotou-se a resolução de (512×512) pixels como padrão de entrada para todas as arquiteturas avaliadas. Essa padronização também se faz necessária para a conversão das imagens em tensores de dimensões fixas, requisito fundamental para o treinamento das redes neurais.

Para preservar integralmente o conteúdo das prescrições e evitar distorções geométricas decorrentes de redimensionamentos não proporcionais, optou-se pela técnica de extensão em branco (*padding*). Nesse procedimento, cada imagem foi posicionada sobre um fundo branco até atingir a resolução de (512×512) pixels, mantendo suas proporções originais e adicionando apenas pixels de preenchimento nas regiões excedentes. Dessa forma, todas as amostras passaram a apresentar dimensões uniformes, tornando-se adequadas para o processamento pelas arquiteturas de aprendizado profundo e permitindo uma comparação metodológica mais justa entre os datasets. Na Figura 4 é possivel ver uma comparação entre imagens antes da padronização e após a padronização, Figura 4a é possivel ver a prescrição do medicamento Lenixil em 103×30 e na Figura 4b após a padronização em 512×512.



(a) (b)

Figura 4: Exemplos de imagens do *PrescriptionBD* após a padronização para resolução de 512×512 pixels.

Para a realização dos experimentos, foram considerados três cenários distintos: treinamento e avaliação utilizando exclusivamente o *PrescriptionBD*, treinamento e avaliação utilizando exclusivamente o *RxHandBD*, e um cenário adicional composto por um dataset combinado, formado pela união das amostras de ambos os conjuntos de dados. Para esse dataset combinado, foi realizada uma nova divisão entre os conjuntos de treinamento e teste, seguindo os *splits* apresentados na Tabela 2. No caso do *PrescriptionBD*, foi preservada a divisão oficial disponibilizada pelos autores, de modo a garantir a reprodutibilidade dos experimentos e a comparabilidade dos resultados.

Tabela 2: Splits utilizados nos diferentes cenários experimentais.

Cenário	**Train**	**Val**	**Test**	**Total**	**Método**
RxHandBD	3905	837	836	5578	70/15/15 por amostra, seed 757
PrescriptionBD	3120	780	780	4680	Split oficial preservado
Combinado	7025	1617	1616	10258	União dos splits correspondentes

Devido à limitada quantidade de amostras disponíveis para treinamento, empregou-se a técnica de *data augmentation* com o objetivo de aumentar a variabilidade dos dados e reduzir o risco de sobreajuste (*overfitting*) dos modelos. As transformações foram aplicadas de forma aleatória durante o treinamento, gerando diferentes variações de uma mesma imagem a cada época.

Foram utilizadas três técnicas de aumento de dados. A primeira consistiu na transformação *RandomAffine*, responsável por aplicar rotações e translações aleatórias às imagens, com probabilidade de 90%. A segunda foi a transformação *ColorJitter*, utilizada para modificar aleatoriamente o brilho e o contraste das imagens, com variação de 0,25 para o brilho e 0,35 para o contraste, sendo aplicada com probabilidade de 60%. Por fim, empregou-se a transformação *GaussianBlur*, que aplica um desfoque gaussiano utilizando *kernel* de tamanho 3 e valor de σ variando entre 0,1 e 0,8, com probabilidade de aplicação de 30%. Na Figura 5 é possivel visualizar o resultado da aplicação da metodologia de aumentação em uma amostra do conjunto de dados *RxHandBD*.



(a) Imagem original (b) Random Affine



(c) ColorJitter (d) Desfoque gaussiano

Figura 5: Exemplo das transformações de data augmentation aplicadas a uma amostra do conjunto de treinamento do RxHandBD.

Essas aplicações permitiram um treinamento dos dados mais conciso com menor ocorrência de over-fitting.

3.2 Computational Models

Para este projeto foram utilizado 4 arquiteturas, e são elas: Uma CNN baseline, CNN com Bilstm, Trocqr e o Parseq

3.2.1 CNN Baseline

As redes neurais convolucionais (*Convolutional Neural Networks* – CNNs) possuem inspiração em princípios observados no sistema visual biológico, especialmente nos estudos sobre o córtex visual realizados por Hubel e Wiesel [5]. Embora não representem uma reprodução fiel do funcionamento do cérebro humano, essas arquiteturas foram concebidas a partir da observação de que o sistema visual é capaz de reconhecer padrões complexos por meio da combinação hierárquica de características visuais simples.

Nos experimentos conduzidos por Hubel e Wiesel, observou-se que neurônios presentes no córtex visual respondem seletivamente a estímulos específicos, como bordas, orientações e contrastes. Além disso, verificou-se que o processamento da informação visual ocorre de forma hierárquica, na qual neurônios de níveis superiores integram informações extraídas por neurônios mais simples para representar estruturas cada vez mais complexas [5].

Inspiradas nesses princípios, as CNNs introduzem o conceito de campos receptivos locais por meio das camadas de convolução, nas quais filtros aprendem automaticamente padrões presentes nas imagens. À medida que múltiplas camadas convolucionais são empilhadas, torna-se possível construir representações hierárquicas das características visuais, iniciando pela detecção

de elementos básicos, como bordas e texturas, e evoluindo para padrões mais complexos, como formas e objetos. Essa organização tornou as CNNs uma das principais arquiteturas para tarefas de visão computacional e reconhecimento de padrões.

Os modelos computacionais das CNNs, tal como são conhecidos atualmente, têm suas bases conceituais no trabalho de Fukushima, apresentado no artigo *Neocognitron: A Self-Organizing Neural Network Model for a Mechanism of Pattern Recognition Unaffected by Shift in Position* [6]. Nesse estudo foi proposta uma arquitetura hierárquica inspirada no córtex visual, composta por camadas responsáveis pela extração progressiva de características e pela obtenção de invariância a pequenas translações dos padrões de entrada. Embora o Neocognitron não utilizasse treinamento por *backpropagation*, seus princípios arquiteturais serviram de base para o desenvolvimento das CNNs modernas.

Posteriormente, LeCun et al. [7] consolidaram esse paradigma ao apresentar uma arquitetura convolucional treinada por *backpropagation* para reconhecimento óptico de caracteres (OCR), demonstrando que a aprendizagem automática de filtros convolucionais possibilitava elevados níveis de desempenho em tarefas de reconhecimento de padrões. Esse trabalho estabeleceu as bases práticas para a ampla adoção das CNNs em problemas de visão computacional.

Esta CNN foi utilizada neste projeto como um modelo de referência (*baseline*), representando o ponto de partida para a comparação entre as arquiteturas avaliadas. Seu emprego permite estabelecer um desempenho inicial para modelos convolucionais tradicionais em tarefas de reconhecimento de prescrições médicas manuscritas, servindo como base para a análise dos ganhos proporcionados por arquiteturas mais sofisticadas.

Entretanto, o problema abordado neste trabalho difere de uma tarefa convencional de classificação de imagens. O objetivo consiste em reconhecer palavras completas presentes nas prescrições, caracterizando um problema de reconhecimento de sequências. Uma CNN convencional realiza apenas uma única classificação para cada imagem de entrada, o que a impede de predizer diretamente todos os caracteres que compõem uma palavra em uma única inferência.

Para contornar essa limitação, a CNN *baseline* foi modelada como um classificador de palavras. Nessa abordagem, cada palavra presente no conjunto de treinamento é tratada como uma classe distinta. Consequentemente, a saída da rede corresponde a uma distribuição de probabilidades sobre todas as classes conhecidas, sendo selecionada como predição a palavra com maior probabilidade. Dessa forma, o modelo não realiza o reconhecimento sequencial dos caracteres, mas estima diretamente a qual palavra previamente aprendida a imagem de entrada pertence.

Como evolução da CNN *baseline*, foi desenvolvida uma arquitetura que incorpora uma camada *Bidirectional Long Short-Term Memory* (BiLSTM). Essa modificação permite que o modelo deixe de realizar apenas a classificação de palavras previamente conhecidas e passe a reconhecer a sequência de caracteres presente na imagem, tornando-o mais adequado para tarefas de reconhecimento de texto manuscrito.

3.2.2 CNN BiLSTM

Posteriormente, visando aumentar a precisão do reconhecimento, foi incorporado um módulo de *Bidirectional Long Short-Term Memory* (BiLSTM) à CNN baseline. Essa arquitetura consiste em uma rede neural recorrente capaz de modelar dependências sequenciais de longo alcance, processando a sequência simultaneamente nos sentidos direto e inverso [8]. Dessa forma, o modelo passa a considerar não apenas o elemento atual, mas também o contexto fornecido pelos caracteres anteriores e posteriores.

A inclusão do BiLSTM justifica-se pelo fato de palavras manuscritas apresentarem uma estrutura sequencial inerente. Em um idioma, determinados caracteres possuem maior probabilidade de ocorrer em conjunto, como a frequente alternância entre consoantes e vogais, além de padrões ortográficos característicos de cada palavra. Ao explorar essas dependências contextuais, o BiLSTM complementa as características visuais extraídas pela CNN, permitindo que a classificação considere tanto a aparência dos caracteres quanto a relação sequencial existente entre eles. Assim, a arquitetura CNN-BiLSTM foi avaliada quanto à sua capacidade de melhorar o reconhecimento de prescrições médicas manuscritas em comparação à CNN baseline.

Com a incorporação do BiLSTM, a arquitetura passou a produzir saídas temporais e foi treinada com CTC sobre um vocabulário de caracteres. Na decodificação gulosa, repetições consecutivas e o símbolo de preenchimento (*blank*) são removidos para reconstruir a palavra predita. Assim, diferentemente da CNN *baseline*, a CNN-BiLSTM não ficou restrita a um conjunto fechado de classes de palavras e pode formar sequências não observadas durante o treinamento, desde que seus caracteres pertençam ao vocabulário aprendido.

Para ampliar a comparação com arquiteturas sequenciais inicializadas a partir de pré-treinamento em larga escala, foram posteriormente avaliados modelos baseados em *Transformers*. Esses modelos também realizam o reconhecimento em nível de sequência de caracteres e podem reconhecer palavras que não estavam presentes no conjunto de treinamento.

3.2.3 TrOCR

O TrOCR (Transformer-based Optical Character Recognition) é um modelo de reconhecimento óptico de caracteres proposto por Li et al [9]. que utiliza uma arquitetura encoder-decoder baseada inteiramente em Transformers. O modelo emprega um Transformer visual para extrair representações da imagem de entrada e um Transformer textual para gerar a sequência correspondente de caracteres ou tokens, eliminando a necessidade de arquiteturas tradicionais baseadas em CNN, RNN e CTC. Além disso, o TrOCR pode ser pré-treinado em grandes conjuntos de dados sintéticos e posteriormente ajustado com dados rotulados, apresentando aplicação em textos impressos, manuscritos e presentes em cenas naturais.

3.2.4 PARSeq

O PARSeq (Permuted Autoregressive Sequence) é um modelo baseado em Transformers desenvolvido para reconhecimento de texto em imagens, especialmente no contexto de Scene Text Recognition [10]. Diferentemente de modelos autoregressivos convencionais, que geram os caracteres seguindo apenas a ordem da esquerda para a direita, o PARSeq utiliza Permutation Language Modeling, permitindo que o modelo aprenda diferentes ordens de predição e explore contexto bidirecional durante o reconhecimento. Essa abordagem possibilita combinar inferência autoregressiva, não autoregressiva e refinamento iterativo em uma única arquitetura, oferecendo bom equilíbrio entre precisão, número de parâmetros e custo computacional.

3.3 Baselines and Metrics

Para a realização das comparações entre as arquiteturas, foi inicialmente definida uma matriz de experimentos, responsável por estabelecer os conjuntos de treinamento e de teste utilizados em

cada modelo. Essa padronização permitiu conduzir avaliações sistemáticas por meio de métricas consistentes, possibilitando analisar o desempenho de cada arquitetura e compreender os fatores que influenciaram os resultados obtidos. Ao final, os resultados de todos os experimentos foram comparados entre si.

Com o objetivo de garantir uma comparação justa entre as arquiteturas, foram definidas matrizes de comparação específicas para cada conjunto de experimentos. Essas matrizes consideram as diferenças conceituais entre os modelos, bem como suas particularidades de treinamento, evitando comparações inadequadas entre abordagens distintas. Dessa forma, foi possível avaliar a capacidade de generalização e o desempenho de cada arquitetura em diferentes cenários e quantidades de dados disponíveis para treinamento.

É possivel visualizar todos os experiemntos na Tabela 3.

Tabela 3: Matriz de experimentos por arquitetura e conjunto de dados.

Exp.	**Arquitetura**	**Dataset**	**Treino**	**Validação**	**Teste**
E1	CNN baseline	PrescriptionBD	3120	780	780
E1	CNN baseline	RxHandBD	3905	837	836
E1	CNN baseline	Combinado	7025	1617	1616
E2	CNN-BiLSTM	PrescriptionBD	3120	780	780
E2	CNN-BiLSTM	RxHandBD	3905	837	836
E2	CNN-BiLSTM	Combinado	7025	1617	1616
E3	TrOCR	PrescriptionBD	3120	780	780
E3	TrOCR	RxHandBD	3905	837	836
E3	TrOCR	Combinado	7025	1617	1616
E4	PARSeq	PrescriptionBD	3120	780	780
E4	PARSeq	RxHandBD	3905	837	836
E4	PARSeq	Combinado	7025	1617	1616

Ao longo de todo o processo de treinamento foram coletadas métricas referentes ao desempenho do modelo em cada época, com o objetivo de compreender a evolução do aprendizado durante o treinamento. Para isso, foram registrados os valores da função de perda (*loss*) nos conjuntos de treinamento e validação, bem como a acurácia obtida em ambos os conjuntos.

Para a avaliação dos modelos, foram utilizadas métricas capazes de analisar diferentes aspectos do desempenho no reconhecimento de texto. A acurácia foi empregada para medir a capacidade do modelo de reconhecer corretamente toda a sequência de caracteres presente em uma imagem. Além disso, foi utilizada a métrica *Character Error Rate* (CER), que quantifica a taxa de erros em nível de caractere, indicando o número de inserções, deleções e substituições necessárias para transformar a predição no texto de referência. Complementarmente, foi utilizada a métrica *Word Error Rate* (WER), que avalia os erros em nível de palavra, medindo a quantidade de palavras reconhecidas incorretamente em relação ao texto esperado.

3.4 Implementation Details

Os experimentos foram implementados em Python utilizando o pacote desenvolvido neste projeto, denominado `med-ocr-research`. O ambiente de execução utiliza Python 3.10 ou superior e tem como principal framework de aprendizado profundo o PyTorch. Todos os treinamentos foram executados com aceleração CUDA em uma GPU NVIDIA GeForce RTX 3050 com 6 GB de memória. A configuração completa do ambiente computacional pode ser visualizada na Tabela 1.

As principais dependências utilizadas durante o desenvolvimento são apresentadas na Tabela 4. Os valores apresentados representam as versões mínimas utilizadas no ambiente experimen-

tal. Para o TrOCR, os arquivos do modelo pré-treinado registram a utilização da biblioteca Transformers na versão 5.12.1.

Tabela 4: Dependências de software utilizadas no ambiente experimental.

Biblioteca	**Versão**	**Biblioteca**	**Versão**
Python	≥ 3.10	PyTorch	≥ 2.2
Torchvision	≥ 0.17	Transformers	5.12.1
NumPy	≥ 1.24	Pandas	≥ 2.0
Pillow	≥ 10.0	Timm	≥ 1.0
PyTorch Lightning	≥ 2.2	Accelerate	≥ 0.30
Albumentations	≥ 1.4	SentencePiece	$\geq 0.2.1$
NLTK	≥ 3.8	Tqdm	≥ 4.66
PyYAML	≥ 6.0	Protobuf	≥ 4.25

Durante todos os experimentos foi utilizada a semente aleatória 42 para garantir a reprodutibilidade dos resultados. Essa semente foi aplicada aos geradores das bibliotecas `random`, NumPy e PyTorch, incluindo a inicialização da CUDA por meio de `torch.cuda.manual_seed_all`. Para a organização dos datasets foi preservado o split oficial do PrescriptionBD. Já para o RxHandBD, foi realizada uma divisão de 70% para treinamento, 15% para validação e 15% para teste, utilizando a semente derivada 757. O dataset combinado foi obtido por meio da união dos respectivos subconjuntos dos dois datasets.

A CNN Baseline e a CNN-BiLSTM foram implementadas computacionalmente neste projeto. Para o TrOCR foi utilizado o checkpoint pré-treinado `microsoft/trocr-small-handwritten`. Já para o PARSeq foi utilizada a implementação disponibilizada no repositório `baudm/parseq`, fixada no commit `1902db043c029a7e03a3818c616c06600af574be`. Todo o código-fonte desenvolvido, bem como as configurações experimentais e os scripts de avaliação, estão disponíveis no repositório do projeto:

`https://github.com/SamuelFerrc/Medical-Handwriting-Ocr`

4 Results and Discussion

Esta seção reúne os resultados das doze avaliações realizadas: quatro famílias de modelos, cada uma avaliada nos datasets PrescriptionBD, RxHandBD e no cenário combinado. A ordem foi organizada para permitir a discussão em três níveis: (i) comparação agregada entre modelos, (ii) efeito do dataset e (iii) análise diagnóstica de cada avaliação. As métricas foram recalculadas diretamente a partir dos arquivos de predições avaliadas. As tabelas detalhadas permanecem disponíveis na pasta de artefatos para consulta, mas não são inseridas no artigo principal para manter a seção de resultados concisa.

4.1 Overall comparison

A comparação agregada por modelo e cenário é apresentada nas Figuras 6, 7 e 8, que mostram, respectivamente, a acurácia de correspondência exata, o CER e o WER para as doze avaliações.

Além dos gráficos, a Tabela 5 apresenta as métricas agregadas de cada modelo e cenário em formato compacto.

Tabela 5: Evaluation summary by model and scenario

Model	Scenario	N	Correct	Accuracy	CER	WER	Mean confidence
CNN	PrescriptionBD	780	322	0.4128	0.5328	0.5911	0.2728
CNN	RxHandBD	836	262	0.3134	0.5866	0.7313	0.2831
CNN	Combined	1616	463	0.2865	0.6467	0.7412	0.2458
CNN-BiLSTM	PrescriptionBD	780	527	0.6756	0.1868	0.3278	0.9822
CNN-BiLSTM	RxHandBD	836	436	0.5215	0.1811	0.4984	0.9767
CNN-BiLSTM	Combined	1616	927	0.5736	0.2064	0.4370	0.9823
TrOCR	PrescriptionBD	780	693	0.8885	0.0864	0.1127	0.9886
TrOCR	RxHandBD	836	612	0.7321	0.1122	0.2824	0.9745
TrOCR	Combined	1616	1307	0.8088	0.1024	0.2018	0.9826
PARSeq	PrescriptionBD	780	703	0.9013	0.0680	0.1000	0.9649
PARSeq	RxHandBD	836	579	0.6926	0.1067	0.3130	0.8880
PARSeq	Combined	1616	1270	0.7859	0.0943	0.2214	0.9344

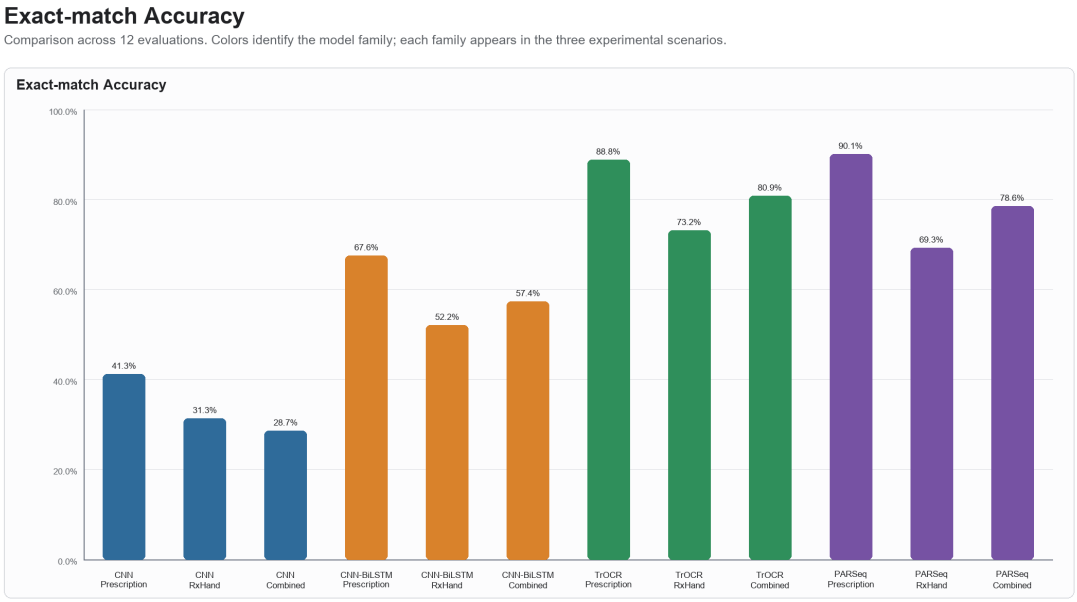


Figura 6: Exact-match accuracy across all twelve evaluations.

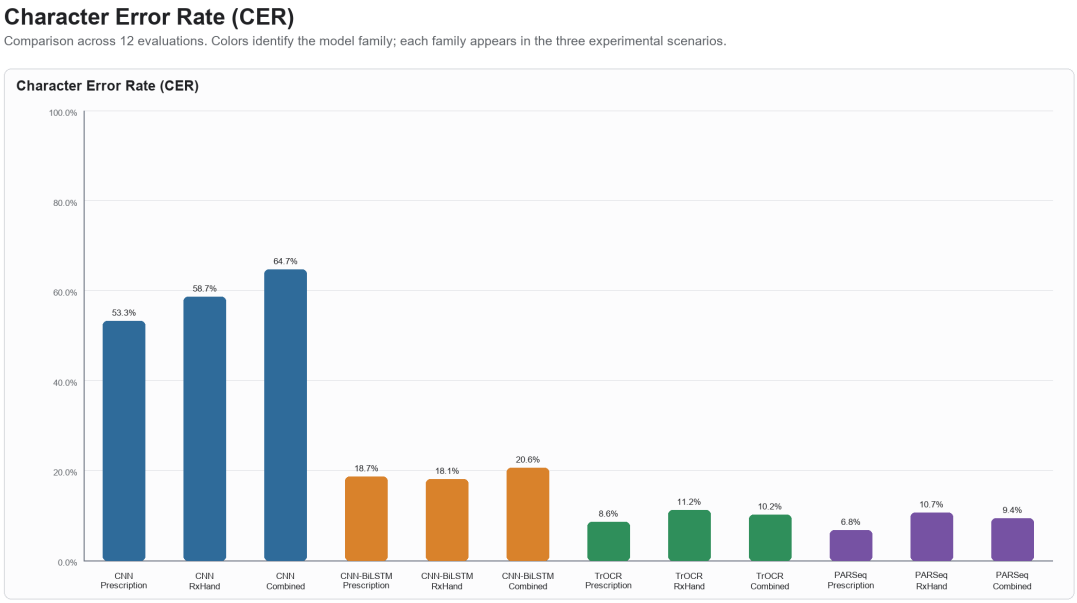


Figura 7: Character Error Rate (CER) across all twelve evaluations.

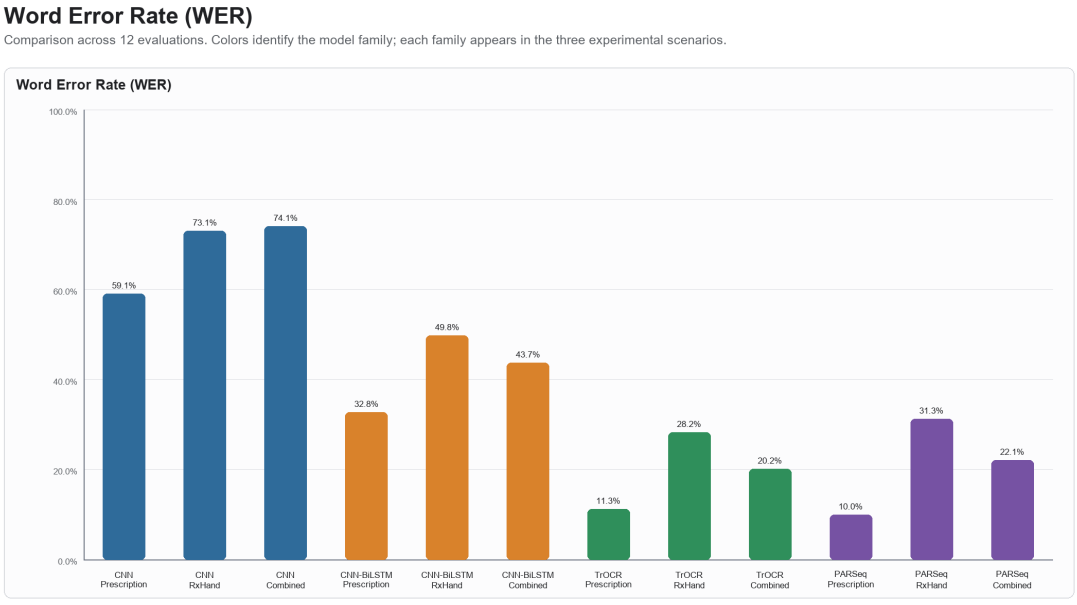


Figura 8: Word Error Rate (WER) across all twelve evaluations.

Os resultados vistos na Figura 6 demonstraram que os modelos apresentaram unanimemente melhor desempenho no conjunto de dados PrescriptionBD. Esse comportamento, entretanto, não foi observado no RxHandBD, no qual a maioria dos modelos obteve desempenho inferior, com exceção da CNN Baseline, que apresentou resultados relativamente mais consistentes.

Essa diferença pode ser atribuída principalmente às características visuais de cada conjunto de dados. Conforme ilustrado na Figura 3, as imagens do RxHandBD apresentam traços mais espessos, borrados e com menor definição, dificultando a extração de características discriminativas tanto pelas CNNs quanto pelos modelos baseados em Transformers. Em contrapartida, a Figura 2 mostra que o PrescriptionBD possui caracteres com traços mais finos, contínuos e bem definidos, favorecendo a identificação de padrões e a aprendizagem de representações mais

robustas pelas redes neurais. Consequentemente, as diferenças na qualidade visual dos conjuntos de dados exerceram influência direta no desempenho dos modelos durante o treinamento e a inferência.

Por sua vez, os experimentos realizados sobre o conjunto de dados combinado apresentaram desempenho intermediário em relação aos dois conjuntos originais. Esse comportamento era esperado, uma vez que o conjunto combinado reúne simultaneamente as características favoráveis do PrescriptionBD e os desafios presentes no RxHandBD. Dessa forma, os modelos foram expostos tanto a exemplos de maior qualidade quanto a amostras com maior complexidade visual, resultando em um desempenho médio entre os dois cenários avaliados.

Uma característica notável foi que a CNN-BiLSTM apresentou um CER menor no conjunto de dados RxHandBD do que no PrescriptionBD, conforme observado na Figura 7. Esse resultado indica que, apesar de o RxHandBD representar um conjunto de dados mais desafiador para a maioria dos modelos avaliados, a arquitetura CNN-BiLSTM foi capaz de reconhecer os caracteres individuais com maior precisão nesse cenário específico.

Em todos os modelos e conjuntos de dados avaliados, o WER apresentou comportamento consistente com a acurácia geral, conforme ilustrado na Figura 8. De maneira geral, modelos que obtiveram maiores valores de acurácia também apresentaram menores valores de WER, evidenciando uma relação inversa entre essas métricas e reforçando a consistência dos resultados experimentais.

4.2 Dataset-specific comparison

Para separar o efeito do cenário combinado do efeito da arquitetura, a Figura 9 apresenta visualmente, por dataset, a comparação de acurácia, CER e WER.

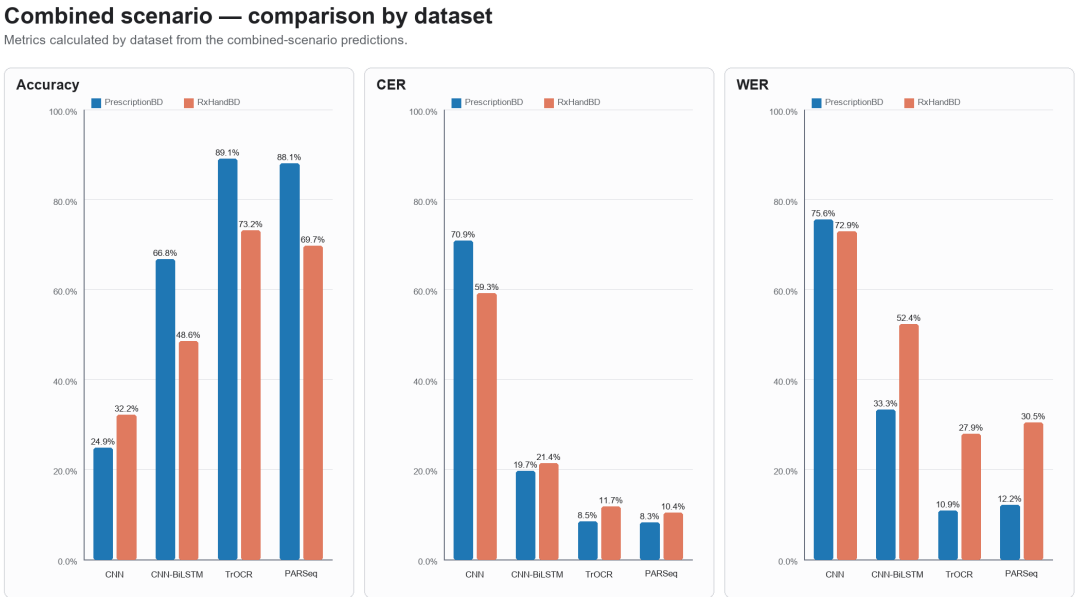


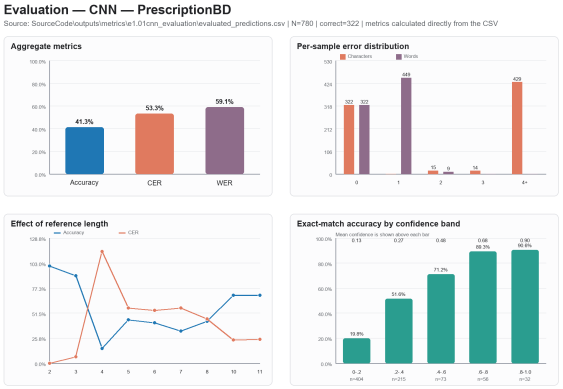
Figura 9: Comparison of the combined scenario by dataset.

Para cada modelo de rede neural, foi calculada a diferença entre os resultados representados pelas barras azul e laranja, em relação a acurácia geral. A CNN Baseline foi o único modelo em que a barra laranja apresentou desempenho superior à barra azul, com uma diferença de 7,3 pontos percentuais. Nos demais modelos, a barra azul obteve desempenho superior, apresentando diferenças de 18,2 pontos percentuais para a CNN-BiLSTM, 15,9 pontos percentuais para o TrOCR e 18,4 pontos percentuais para o PARSeq.

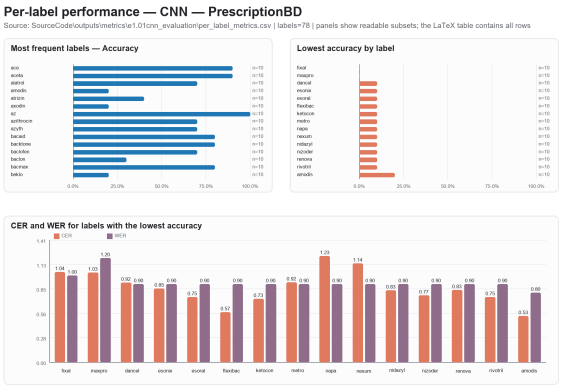
4.3 Per-evaluation diagnostic views

As figuras desta subseção complementam as métricas agregadas. Cada painel de predições avaliadas reúne distribuição de erros, relação entre desempenho e comprimento da referência e acurácia por faixa de confiança. O painel por rótulo mostra a distribuição de desempenho entre palavras, destacando os rótulos mais frequentes e os rótulos com menor acurácia. Esses painéis são descritivos e devem ser usados para investigar padrões de erro, não como substitutos das métricas agregadas.

4.3.1 CNN baseline

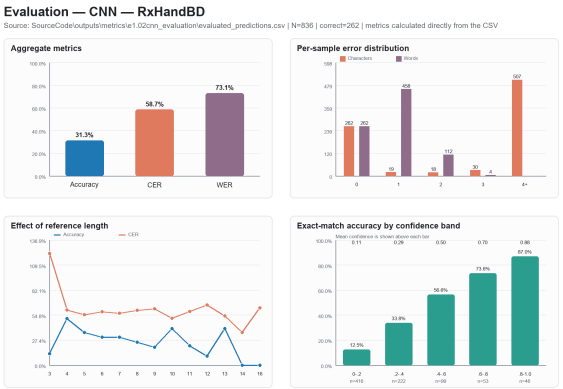


(a) Evaluated predictions.

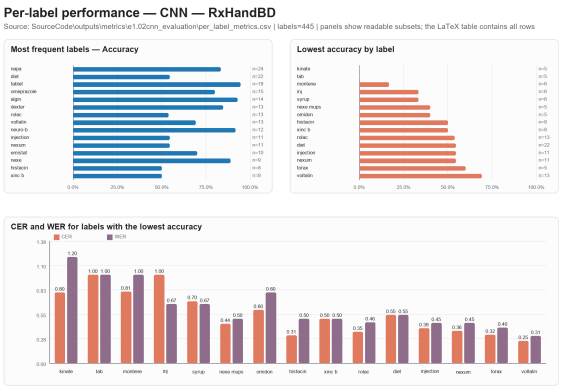


(b) Per-label metrics.

Figura 10: CNN baseline evaluated on PrescriptionBD.

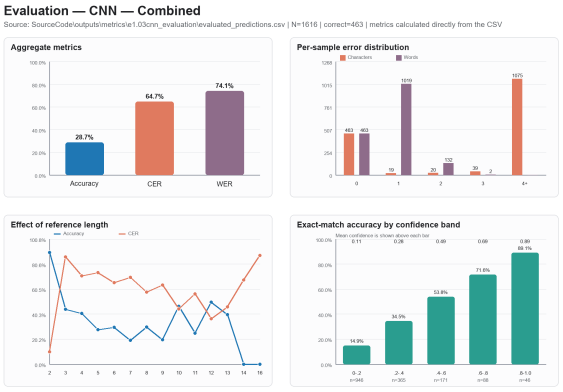


(a) Evaluated predictions.

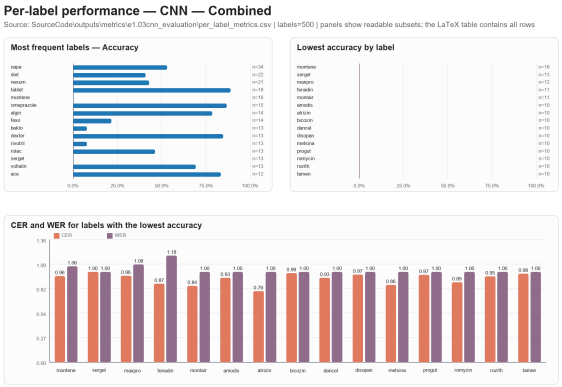


(b) Per-label metrics.

Figura 11: CNN baseline evaluated on RxHandBD.



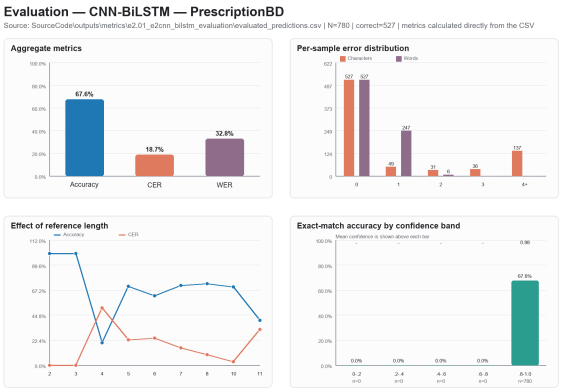
(a) Evaluated predictions.



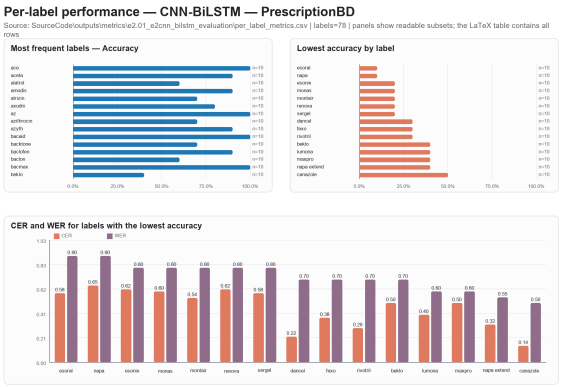
(b) Per-label metrics.

Figura 12: CNN baseline evaluated in the combined scenario.

4.3.2 CNN-BiLSTM

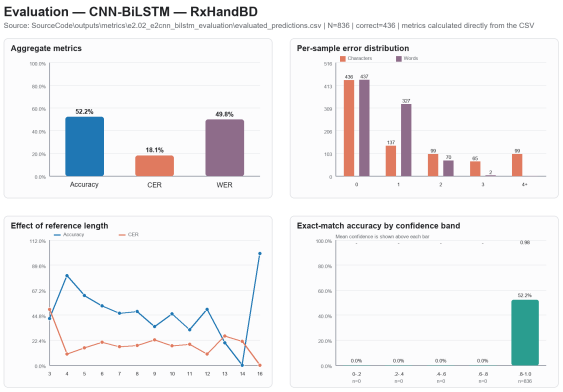


(a) Evaluated predictions.

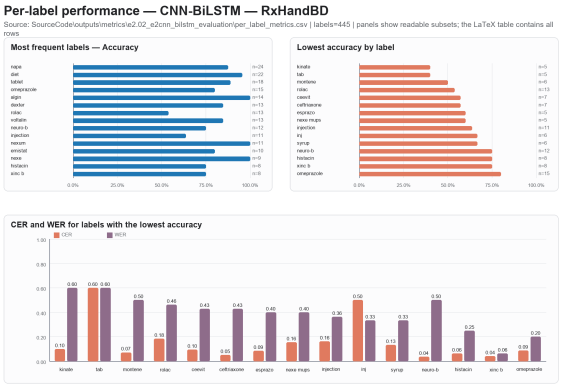


(b) Per-label metrics.

Figura 13: CNN-BiLSTM evaluated on PrescriptionBD.

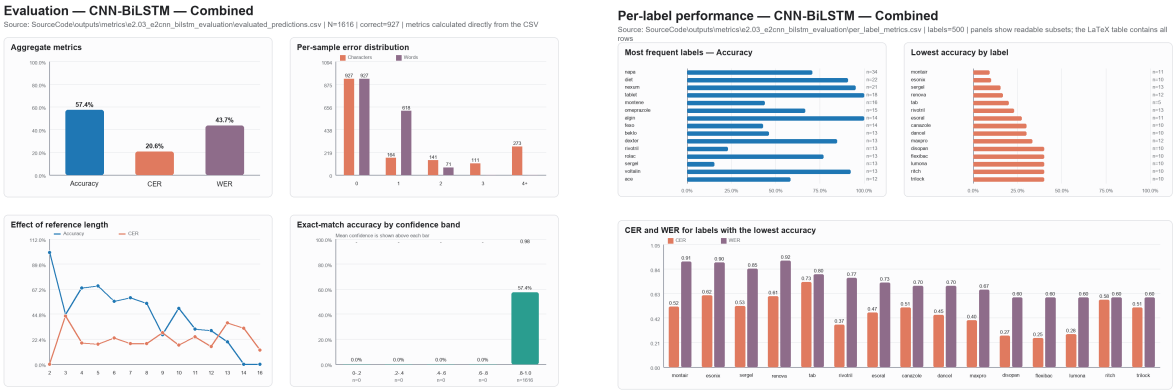


(a) Evaluated predictions.



(b) Per-label metrics.

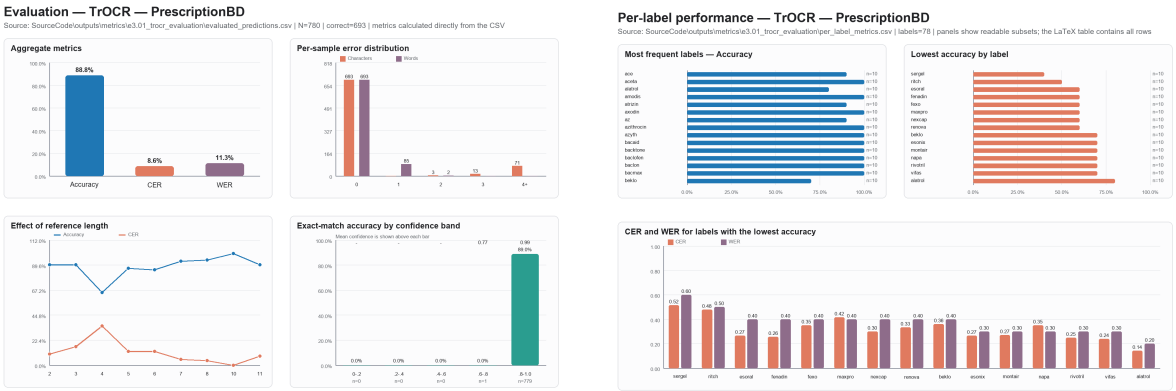
Figura 14: CNN-BiLSTM evaluated on RxHandBD.



(a) Evaluated predictions. (b) Per-label metrics.

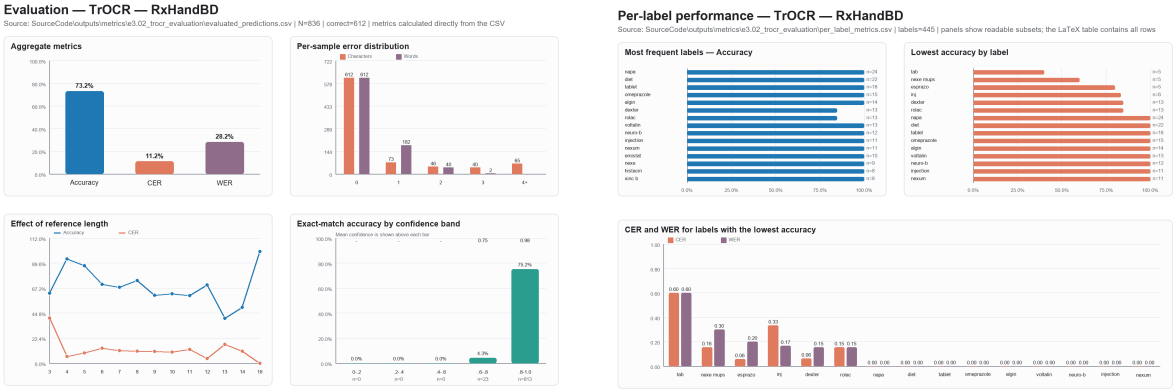
Figura 15: CNN-BiLSTM evaluated in the combined scenario.

4.3.3 TrOCR



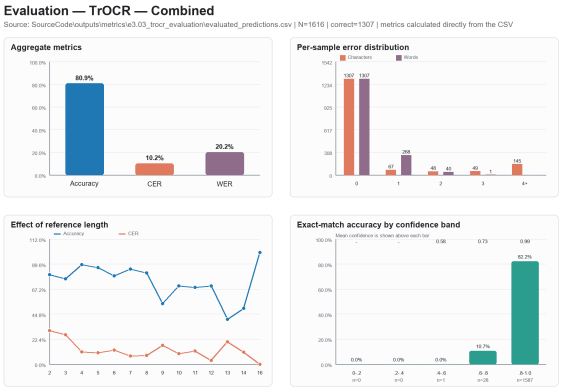
(a) Evaluated predictions. (b) Per-label metrics.

Figura 16: TrOCR evaluated on PrescriptionBD.

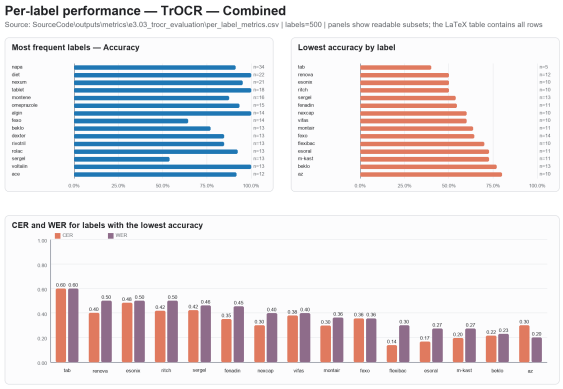


(a) Evaluated predictions. (b) Per-label metrics.

Figura 17: TrOCR evaluated on RxHandBD.



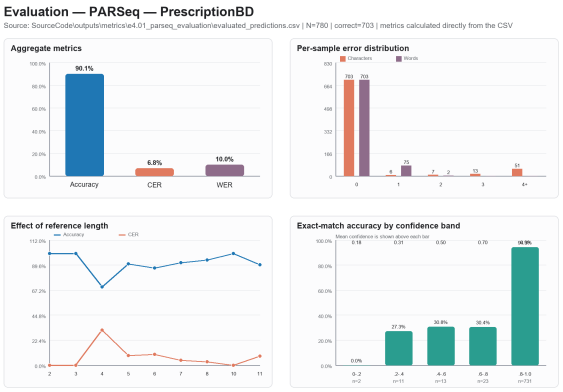
(a) Evaluated predictions.



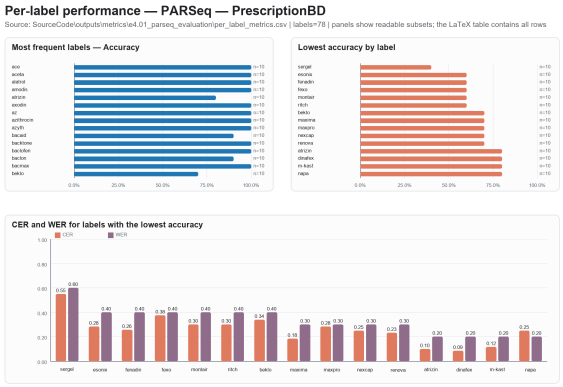
(b) Per-label metrics.

Figura 18: TrOCR evaluated in the combined scenario.

4.3.4 PARSeq

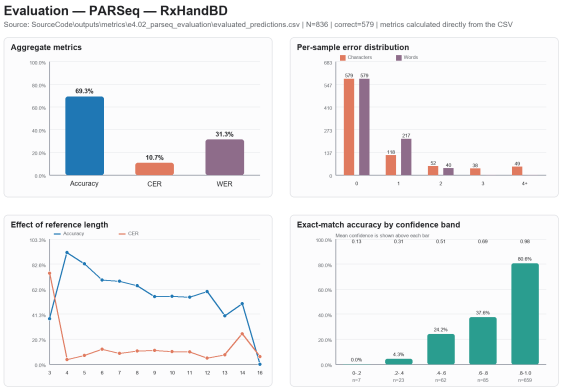


(a) Evaluated predictions.

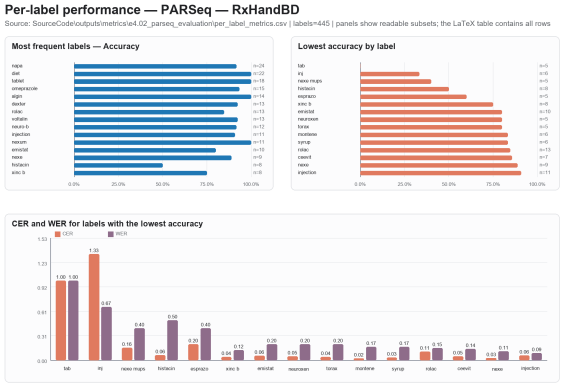


(b) Per-label metrics.

Figura 19: PARSeq evaluated on PrescriptionBD.

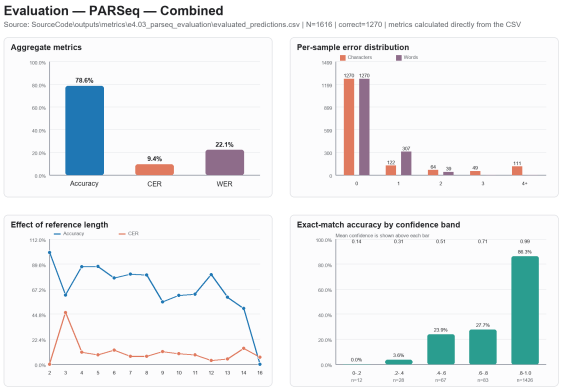


(a) Evaluated predictions.

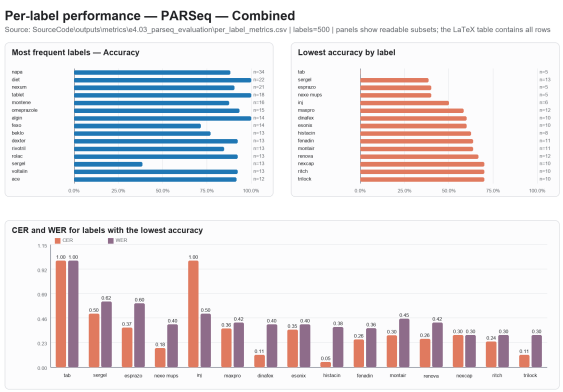


(b) Per-label metrics.

Figura 20: PARSeq evaluated on RxHandBD.



(a) Evaluated predictions.



(b) Per-label metrics.

Figura 21: PARSeq evaluated in the combined scenario.

5 Limitations

Este trabalho apresentou limitações relacionadas à quantidade de dados utilizada e ao tamanho dos *batches* de treinamento, restritos pela capacidade de memória disponível. Essas limitações podem ter introduzido algum viés nos resultados obtidos. Entretanto, todos os modelos foram treinados e avaliados sob as mesmas condições experimentais, utilizando o mesmo ambiente computacional e configurações de treinamento, de forma a garantir a maior equidade possível na comparação entre os métodos.

6 Conclusion

Os resultados obtidos evidenciam o potencial dos modelos de reconhecimento sequencial para a transcrição de palavras manuscritas em prescrições médicas. Em particular, TrOCR e PARSeq alcançaram os melhores desempenhos entre os métodos avaliados, com vantagens consistentes em relação à CNN baseline nos três cenários experimentais. O PARSeq destacou-se no PrescriptionBD, atingindo 90,13% de acurácia, CER de 0,0680 e WER de 0,1000, enquanto o TrOCR apresentou o melhor desempenho global no cenário combinado em acurácia (80,88%) e WER (0,2018). Esses resultados mostram que o uso de modelos pré-treinados, adaptados por *fine-tuning*, constitui uma estratégia eficaz para OCR de escrita médica manuscrita mesmo em um cenário de disponibilidade limitada de dados.

Code and Data Availability

O código, os dados e os materiais suplementares estão disponíveis em: `https://github.com/SamuelFerrc/Medical-Handwriting-Ocr`.

Referências

[1] Usman Ali, Sahil Ranmbail, Muhammad Nadeem, Hamid Ishfaq, Muhammad Umer Ramzan, and Waqas Ali. Leveraging deep learning with multi-head attention for accurate extraction of medicine from handwritten prescriptions, 2024. URL `https://doi.org/10.48550/arXiv.2412.18199`.

[2] Md Masudul Islam. RxHandBD: A handwritten prescription word image dataset. Mendeley Data, 2026. Version 3.

[3] Abdur Rahim Mia, Abdullah Al Mamun, Abdullah Al Sajid, and Aurunave Mollik Ruddra. Doctor's handwritten prescription BD dataset. Kaggle, 2024. URL `https://www.kaggle.com/dsv/8378585`.

[4] A. R. Mia, M. A.-A.-S. Chowdhury, A. A. Mamun, A. M. Ruddra, and N. T. Tanny. A deep neural network approach with pioneering local dataset to recognize doctor's handwritten prescription in bangladesh. In *2024 International Conference on Advances in Computing, Communication, Electrical, and Smart Systems (iCACCESS)*, Dhaka, Bangladesh, 2024.

[5] David H. Hubel and Torsten N. Wiesel. Receptive fields, binocular interaction and functional architecture in the cat's visual cortex. 1962.

[6] Kunihiko Fukushima. Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position. *Biological Cybernetics*, 36(4):193–202, 1980. doi: 10.1007/BF00344251.

[7] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998. doi: 10.1109/5.726791.

[8] Baoguang Shi, Xiang Bai, and Cong Yao. An end-to-end trainable neural network for image-based sequence recognition and its application to scene text recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 2564–2572, 2016. doi: 10.1109/CVPR.2016.277.

[9] Minghao Li, Tengchao Lv, Jingye Chen, Lei Cui, Yijuan Lu, Dinei Florencio, Cha Zhang, Zhoujun Li, and Furu Wei. TrOCR: Transformer-based optical character recognition with pre-trained models. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pages 13094–13102, 2023. doi: 10.1609/aaai.v37i11.26538.

[10] Darwin Bautista and Rowel Atienza. Scene text recognition with permuted autoregressive sequence models. *arXiv preprint arXiv:2207.06966*, 2022.